CODEX HASH

RESEARCH LABORATORY

¿El alcalde mejora la ciudad más allá del azar? Un dato faltante en el cambio de alcalde hace que la prueba diga que sí

Costura de lagunas, correlación serial y el tamaño de la prueba de permutación de Berry y Fowler en un panel de municipios brasileños

Carlos Ulisses Flores

Codex Hash Research Laboratory

ORCID: 0000-0002-6034-7765

Fecha: 7 de noviembre de 2026

Resumen

La prueba de inferencia por aleatorización para efectos del líder (RIFLE) de Berry y Fowler (2021) compara cuánto explican un resultado los mandatos verdaderos con cuánto lo explicarían mandatos de la misma duración en orden sorteado, y se ha convertido en la forma directa de preguntar si un gobernante importa "más allá del azar". Para los años sin dato, el artículo original y la opción por defecto del paquete oficial para Stata (Berry & Fowler, 2018) descartan las observaciones faltantes y cosen los bloques restantes en un tiempo continuo. Este artículo muestra que esa costura, bajo correlación serial modesta, hace que la prueba señale un efecto del líder inexistente cuando, en el panel municipal examinado, la laguna cae junto a un cambio de alcalde (el regreso del mismo alcalde después de la laguna puede invertir el efecto), y que la magnitud del error crece con el número de unidades del panel. La evidencia proviene de simulaciones bajo la hipótesis nula sobre la estructura real de mandatos de 5.468 municipios brasileños (2005-2024), ejecutadas en una traducción de la ruta por defecto del código oficial y registradas en una cadena de hash antes de cada ejecución. Con una laguna de un medio mandato justo después de la elección (en el 62,3% de los 5.468 municipios separa a alcaldes diferentes) y ruido autorregresivo de coeficiente 0,217, el rechazo al 5% llega al 76,6% en el panel completo y al 89,4% cuando la laguna es vecina de un cambio; con 50 municipios, varía del 6,8% al 8,2%, y solo la celda vecina de un cambio sigue siendo compatible con el 5%. Con la máscara real de disponibilidad del índice del estudio, el rechazo es del 34,8%. Sin correlación serial, la laguna del periodo 9 da un 6,4%, compatible con el 5%. Con la opción `nostitch` que ofrece el propio paquete, la inflación de decenas de puntos desaparece: 4,6% con 1.000 municipios, 3,6% con la máscara real y del 1,2% al 2,0% en el panel completo, una prueba conservadora, aunque por encima del 0,2% que el paquete rechaza sin ninguna laguna; en las celdas de 1.000 municipios en

las que se midió la potencia, sin tramos descartados y sin igualar el tamaño de las pruebas, esta fue similar a la del control sin laguna. Con la laguna en medio de un mandato largo, la prueba resultó conservadora, pero el signo depende de la posición de la laguna respecto de las fronteras de los mandatos. La ayuda del paquete recomienda desactivar la costura ante “una laguna larga” o ante otra razón que no especifica; los resultados indican que la longitud no basta y que la posición de la laguna respecto del cambio de líder debe entrar en el diagnóstico. El artículo no afirma que ningún resultado publicado de Berry y Fowler esté equivocado y no presenta la corrección como nueva: ya existe en el paquete. El caso que motivó la investigación, un estudio prerregistrado sobre alcaldes brasileños, terminó sin evidencia de efecto del alcalde y con la conclusión de equivalencia no demostrada.

Palabras clave: inferencia por aleatorización; efectos del líder; datos faltantes; correlación serial; prerregistro; alcaldes

1. Introducción

Preguntar si un gobernante importa es preguntar si el resultado cambia con la persona, y el RIFLE lo prueba comparando la historia real con historias sorteadas. Jones y Olken (2005) mostraron que la muerte de jefes de Estado en el cargo altera el crecimiento, y reavivaron una línea que busca separar el efecto de la persona del efecto del contexto. Berry y Fowler (2021) propusieron un procedimiento más directo para la pregunta "más allá del azar": regresar el resultado sobre indicadores de líder, guardar el R^2 y compararlo con la distribución del R^2 obtenida cuando se baraja el orden de los mandatos de cada unidad, manteniendo la duración de cada uno. Si los mandatos verdaderos explican más que casi todos los sorteos, se rechaza la hipótesis de efecto nulo. Los autores aplicaron la prueba a jefes de Estado, gobernadores y alcaldes de los Estados Unidos, ejecutivos de empresas y entrenadores deportivos, y la pusieron a disposición como módulo para Stata (Berry & Fowler, 2018). Este artículo muestra que, cuando faltan años en medio de la serie, la forma por defecto de tratar la laguna puede hacer que la prueba señale a un líder que no existe.

El procedimiento depende de una elección que parece de trastienda: qué hacer con los años sin dato. El artículo original es explícito: "we drop those observations and stitch together blocks of time, coding a new time variable so that we have a single, contiguous stretch of time with complete data for each unit" (Berry & Fowler, 2021) ("descartamos esas observaciones y cosemos los bloques de tiempo, codificando una nueva variable de tiempo para tener un único tramo continuo de datos completos en cada unidad"). El paquete hace lo mismo por defecto y ofrece la opción `nostitch`, descrita en la ayuda como la que debe usarse "if there is a long gap between periods or some other reason not to comprate [*sic*] observations across missing periods" (Berry & Fowler, 2018) ("si hay una laguna larga entre periodos u otra razón para no comparar

observaciones a través de periodos faltantes"). Ninguna de las simulaciones de tamaño de los autores combina laguna y correlación serial: las de 20 unidades por 20 periodos, con peso 0 o 0,2 en el periodo anterior, no tienen lagunas; las de cambio endógeno de líder, con el número de unidades y de periodos de cada aplicación, encadenan el resultado simulado en el orden de las filas, ordenadas por el calendario pero aplicando la correlación a la fila anterior aun cuando el año salta, según el código de replicación (Berry & Fowler, 2020), y por eso no producen el desajuste entre calendario y tiempo cosido del que trata este artículo; las de potencia, que con efecto cero miden cerca de un 5% de rechazo, usan ruido independiente; y las del material suplementario tratan del costo de transición en paneles completos, sin correlación serial.

Este artículo nació de un estudio prerregistrado que aplicó el RIFLE a alcaldes brasileños, con un índice de nota escolar, ingresos propios y mortalidad infantil, de 2005 a 2024. En la fase piloto, antes de cualquier cálculo con los alcaldes verdaderos, la prueba con la costura rechazó la hipótesis nula verdadera en el 64,0% de 200 simulaciones en los municipios con laguna interior, cuando lo correcto sería el 5% (Sección 5.6). El estudio se detuvo y se rehízo, y la pregunta pasó a ser otra: ¿qué es lo que, en la laguna, engaña a la prueba?

La respuesta tiene cuatro partes, todas medidas en una traducción fiel del código oficial:

1. **En el panel municipal examinado, la costura por defecto rechaza en exceso cuando la laguna cae junto a un cambio de alcalde** y el resultado tiene correlación serial positiva (Sección 5.1); cuando el mismo alcalde vuelve después de la laguna, el signo puede invertirse (Sección 3.2).
2. **La longitud de la laguna no basta para evaluar el riesgo.** Una laguna corta, de un único periodo por municipio, ya puede distorsionar bajo correlación serial, y el signo de

la distorsión depende de dónde cae la laguna respecto de las fronteras de los mandatos; en la celda probada, la laguna en medio de un mandato largo dejó la prueba conservadora (Secciones 3.2, 3.3 y 5.1).

3. **El error aumenta fuertemente en los paneles más grandes examinados**: con 50 municipios varía del 6,8% al 8,2% (solo la celda vecina de un cambio sigue siendo compatible con el 5%) y llega al 89,4% con 5.468 (Sección 5.2).

4. **La opción `nostitch`, que ya existe en el paquete, elimina la inflación de decenas de puntos** en los casos probados; en el panel completo, la prueba resulta conservadora, y la potencia, medida solo con 1.000 municipios, fue similar a la del control sin laguna (Secciones 5.1 a 5.3).

La ayuda del paquete ya incluye la opción que restringe el sorteo a tramos continuos; las partes 1 a 3 y la medida de la parte 4 no están en el artículo original, en su material suplementario, en el código de replicación de los autores ni en la ayuda, y no se localizaron en las demás fuentes examinadas (Sección 6.3). El artículo no reivindica la corrección, que es de los autores; reivindica la medida del problema, los ejemplos de cambio de signo y un diagnóstico para decidir cuándo usarla. Tampoco afirma que ningún resultado publicado de Berry y Fowler esté equivocado (Sección 6.2).

2. Trabajos relacionados

La pregunta sobre los líderes ya se ha hecho muchas veces; en las fuentes examinadas, no localizamos una medida del tamaño de la prueba cuando falta un dato en medio de la serie. La descomposición de la varianza por líder tiene una historia de controversia sobre cuánto excede al azar el "efecto del ejecutivo". El diseño de Jones y Olken identifica el efecto mediante

pocos cambios inesperados, 57 en un panel de 130 países desde 1945 según Berry y Fowler (2021), y el RIFLE usa todos los cambios. Fitza (2014) mostró que buena parte de la varianza atribuida a los presidentes de empresa podía reproducirse por suerte; Quigley y Graffin (2017) respondieron que el efecto es significativo y mayor que el azar. El RIFLE (Berry & Fowler, 2021) transformó esa discusión en una prueba de permutación con una regla de decisión clara, y Smith y Gray (2021) lo extendieron a series históricas largas y lo revalidaron en datos simulados. De los 42 registros que citan a Berry y Fowler en OpenAlex (31 de octubre de 2026; algunos son versiones de un mismo trabajo), ningún título menciona lagunas ni el tamaño de la prueba; el cribado es débil y no recuperó a Smith y Gray. Este artículo solo leyó el resumen de esa extensión, que no menciona lagunas; como las series históricas suelen tener años faltantes, el texto completo puede tratar el problema (ver Sección 6.3).

La validez de una prueba de permutación proviene de la simetría de los datos bajo la hipótesis nula, no de la hipótesis nula en sí. Lehmann y Romano (2005) presentan el resultado clásico: la prueba es exacta cuando la distribución conjunta de los datos es invariante bajo el grupo de permutaciones usado. Winkler et al. (2014) discuten lo que ocurre cuando esa intercambiabilidad solo vale en bloques y por qué pueden ser necesarias restricciones al sorteo. Canay, Romano y Shaikh (2017) tratan las pruebas de aleatorización bajo una simetría solo aproximada. La lección común es que “efecto del líder cero” no implica, por sí solo, que todos los órdenes de mandato sean igualmente probables; eso depende de la estructura de dependencia del resultado, y es exactamente esa estructura la que la costura altera.

Remuestrear datos dependientes exige preservar la dependencia que importa. La literatura de bootstrap por bloques (Künsch, 1989; Politis & Romano, 1994; Lahiri, 2003) muestra que los bloques contiguos preservan la dependencia local de las series estacionarias y que las uniones

entre bloques son justamente donde esa dependencia deja de reproducirse; el bootstrap estacionario empalma bloques a propósito y sigue siendo consistente, porque trata las uniones como parte del diseño. El RIFLE no es un bootstrap y las justificaciones son diferentes, pero el principio se transfiere: reordenar bloques en un índice de tiempo que no corresponde al calendario compara particiones bajo covarianzas que no son las que tienen los datos.

En Brasil, la pregunta sobre los alcaldes se ha hecho con otros diseños. Akhtari, Moreira y Trucco (2022) mostraron, con elecciones reñidas, que el cambio de partido al mando del municipio cambia a directores y profesores y reduce la nota de los alumnos; Brollo y Nannicini (2012) mostraron que los alcaldes alineados con el presidente reciben más transferencias discrecionales para infraestructura en años preelectorales, razón por la cual el estudio prerregistrado retiró del resultado el efecto de la alineación partidaria. Según el relevamiento hecho para este artículo (Sección 6.3), el RIFLE no se había aplicado a alcaldes brasileños, con la confianza media declarada allí. El estudio siguió la lógica de prerregistro defendida por Nosek et al. (2018): reglas de decisión grabadas antes de los datos, enmiendas fechadas y nada descartado después de ver el resultado.

3. El procedimiento, la costura y el mecanismo

3.1 El RIFLE y lo que hace la costura

La prueba compara una partición real con particiones sorteadas, y la costura cambia qué particiones son posibles. Para cada unidad m con periodos $t = 1, \ldots, T$, el resultado y se residualiza por efectos de periodo. El R^2 real proviene de la regresión sobre indicadores de líder; cada permutación sortea el orden de los mandatos de la unidad, manteniendo la duración, y

recalcula el R^2. El valor p es la fracción de permutaciones con R^2 mayor que el real. En el código oficial (`rifle.ado`, Berry & Fowler, 2018), tres detalles importan aquí:

- el resultado se residualiza por periodo antes de descartar los faltantes, lo que, para un resultado faltante, equivale a descontar la media del periodo en las celdas observadas;
- los indicadores son de la **identidad** del líder (`absorb(leader)`), de modo que la misma persona en dos mandatos separados forma un único grupo;
- el periodo de mando ("stint") cambia cuando cambia el líder, en el orden del tiempo renumerado, de modo que la misma persona a ambos lados de una laguna cosida se convierte en un solo periodo de mando.

Con la costura, el periodo posterior a la laguna pasa a ser vecino, en el índice de tiempo, del periodo anterior a ella. Con `nostitch`, cada tramo continuo de periodos observados se convierte en una unidad propia de sorteo, y el tramo con un solo líder y dos o más filas sale de la muestra.

3.2 Dos líderes bastan para ver el mecanismo

La covarianza entre dos periodos sigue siendo la del calendario, no la del índice cosido. Sea el resultado, bajo la hipótesis nula, un proceso autorregresivo estacionario con varianza σ^2 y covarianza $\sigma^2\rho^{|t-s|}$ entre los periodos t y s del calendario, con $0 < \rho < 1$. Para una partición G en grupos g de tamaño n_g, la suma de cuadrados explicada es, salvo un término común a todas las particiones,

$$Q = \sum_{g} \frac{1}{n_g} \left(\sum_{t \in g} y_t \right)^2 , \tag{1}$$

y el denominador del R^2 es el mismo en todas las permutaciones de una misma base. Ordenar el R^2 equivale, entonces, a ordenar Q, cuya esperanza es

$$\mathrm{E}[Q] = \sum_{g} \frac{1}{n_g} \sum_{t,s \in g} \sigma^2 \, \rho^{|t-s|}. \tag{2}$$

Considérense seis periodos con el líder A en 1-2 y B en 3-6, y la única reordenación posible, B antes que A.

- **Laguna vecina del cambio** (falta el periodo 3): la partición real es {1, 2} | {4, 5, 6}; la invertida, en la secuencia cosida, es {1, 2, 4} | {5, 6}. La partición invertida pone la laguna dentro de un grupo, donde reduce la covarianza interna. Con Q_{inv} el valor del orden invertido, resulta

$$\mathrm{E}[Q_{\mathrm{real}} - Q_{\mathrm{inv}}] = \frac{2}{3}\sigma^2(\rho - \rho^3) > 0, \tag{3}$$

  y el ajuste real queda favorecido sin ningún efecto del líder.

- **Laguna dentro del mandato** (falta el periodo 4): la partición real es {1, 2} | {3, 5, 6}, y la invertida, {1, 2, 3} | {5, 6}. Los papeles se intercambian:

$$\mathrm{E}[Q_{\mathrm{real}} - Q_{\mathrm{inv}}] = -\frac{2}{3}\sigma^2(\rho - \rho^3) < 0, \tag{4}$$

  y la diferencia media va en el sentido conservador, a favor del sorteo.

- **Laguna dentro del mandato que aun así infla** (contraejemplo de la revisión externa): con A en 1-4, B en 5-6 y el periodo 2 faltante, la partición real es {1, 3, 4} | {5, 6} y la invertida, {1, 3} | {4, 5, 6}. Entonces

$$\mathrm{E}[Q_{\mathrm{real}} - Q_{\mathrm{inv}}] = \frac{1}{3}\sigma^2\rho(1-\rho)(1-2\rho), \tag{5}$$

positivo para $\rho < 0{,}5$ (cerca de $0{,}032\sigma^2$ con $\rho = 0{,}217$). La laguna está dentro del mandato de A, y el ajuste real queda favorecido.

- **Laguna vecina del cambio con diferencia media negativa** (segundo contraejemplo de la revisión externa): con A en 1-2, B en 3-4, A de vuelta en 5-6 y el periodo 3 faltante, el paquete sortea tres periodos de mando y reúne los dos de A en un solo grupo; la media sobre los seis órdenes da

$$\mathrm{E}[Q_{\mathrm{real}} - Q_{\mathrm{perm}}] = -\frac{1}{6}\sigma^2\rho^2(1-\rho)(2\rho^2+4\rho+3), \tag{6}$$

cerca de $-0{,}024\sigma^2$ con $\rho = 0{,}217$. En ese caso el regreso de A ya desplaza el estadístico en el sentido conservador incluso sin ninguna laguna (cerca de $-0{,}102\sigma^2$ con los seis periodos completos, por la misma enumeración), porque los dos periodos de mando de A nunca son vecinos en los datos reales y pasan a serlo en cuatro de los seis órdenes; la laguna reduce ese desplazamiento, pero no lo invierte. Es la misma candidata a causa del conservadurismo del paquete sin laguna (Sección 5.1).

Los ejemplos usan la covarianza del calendario antes del descuento de la media del periodo, que la prueba realiza; con máscaras diferentes entre municipios, ese descuento cambia la matriz de covarianza y vincula las unidades, de modo que el paso de los ejemplos al panel es un argumento heurístico, y las simulaciones aplican el descuento exactamente. Con $\rho = 0$ los cuatro contrastes desaparecen. El signo depende, por lo tanto, de cómo se posiciona la laguna respecto de las fronteras de los grupos reales y de los sorteados, incluidos los grupos que reúnen a un líder que vuelve, y no solo de que esté junto a un cambio o dentro de un mandato. Esos signos son de

diferencias medias, no de tasas de rechazo: en un panel de dos municipios con la estructura del segundo ejemplo, la diferencia media es negativa y, aun así, la prueba rechaza en el 48,1% de 4.000 bases (el orden real tiene un R^2 mayor que el invertido en el 47,3% de 400 mil bases, con ruido gaussiano y el descuento de la media del periodo), porque los residuos de los dos municipios son opuestos, los tres órdenes que no son el real quedan del mismo lado de él, y el valor p exacto, contando solo los órdenes estrictamente mayores, es 0 o 0,75; con 200 sorteos, la estimación oscila en torno a esos dos polos. Esa patología de paneles minúsculos con cola estricta existe incluso sin laguna y sin correlación serial, y no es el mecanismo de la costura. La derivación fue propuesta por la revisión externa de este trabajo (Sección 4.4); las tasas de rechazo se midieron por simulación.

3.3 Por qué el panel grande amplifica y la longitud no decide

El desplazamiento por unidad es pequeño, pero se suma; la dispersión de la prueba crece más despacio. Si el desplazamiento medio por municipio en la diferencia entre la suma de cuadrados explicada real y la permutada tiene un signo definido en el conjunto del panel, positivo cuando predominan las lagunas vecinas de un cambio sin regreso del líder, la suma sobre N unidades independientes crece con N, mientras que su dispersión bajo la hipótesis nula crece aproximadamente con $\sqrt{N}$. En el R^2, que divide las dos sumas por la suma de cuadrados total, también proporcional a N, el desplazamiento queda de orden constante y la dispersión cae con $1/\sqrt{N}$; la razón entre ambos crece con $\sqrt{N}$ en los dos casos. Por eso el mismo sesgo por unidad es casi invisible en 50 unidades y decisivo en miles; en las simulaciones, cada tamaño usa otra submuestra, y el crecimiento concuerda con el mecanismo sin aislarlo. La longitud de la laguna entra en la covarianza perdida (el par empalmado pasa de ρ a ρ^{L+1}), pero no decide el signo: la misma laguna corta desplaza el estadístico a favor del ajuste real cuando separa a dos

líderes diferentes que no vuelven, puede desplazarlo hacia cualquier lado cuando queda dentro de un mandato y, en los casos de regreso calculados aquí, lo desplaza en el sentido conservador, conforme a las fronteras de la Sección 3.2.

4. Datos y diseño de las simulaciones

4.1 La traducción del código oficial y su límite

Los números principales provienen de una traducción de la ruta por defecto del `rifle.ado` distribuido en el SSC (la versión con las opciones `controls` y `notrend`; la copia `RIFLE.do` del código de replicación no las tiene, pero la costura y el `nostitch` son idénticos) a Python, porque no había Stata disponible; ese es el principal límite del artículo. La traducción cubre el R^2 sin controles, la costura y el `nostitch`; no implementa las opciones `controls`, `growth` y `notrend`, y supone que solo el resultado tiene faltantes (unidad, líder y periodo siempre presentes, como en las simulaciones). Reproduce los pasos citados en la Sección 3.1, con la línea correspondiente del código anotada (`code/rifle_ado.py` en el paquete de replicación; Flores, 2026). Se cotejó con cálculos hechos a mano en paneles pequeños (tres pruebas que cubren la costura, la fusión de la misma persona y las reglas del `nostitch`), con la enumeración exacta de los 36 órdenes de periodos de mando en un panel de dos unidades con un líder que vuelve (el valor p del sorteo da 0,1103 con 200 mil permutaciones, frente a 0,1111 exacto), con la misma enumeración en un panel con `nostitch`, un tramo descartado, un tramo de una fila y la misma persona en los dos tramos (0,7511 frente a 0,75 exacto), con una reconstrucción independiente de la media que incluye la fila real (igual hasta el 12.º decimal y diferente de la media sin ella) y con el motor propio del estudio en un panel sin regreso de alcalde, donde los dos coinciden en el valor registrado en la cadena (R^2 de 0,4777757). Esto no sustituye una confrontación con Stata,

que el paquete de replicación deja preparada en el archivo `stata/rifle_celulas.do` para quien lo tenga (Sección 7).

4.2 La estructura de mandatos

La estructura es real; el resultado es sintético. Los alcaldes de cada medio mandato (diez periodos de dos años, 2005-2024) se identificaron a partir de los datos abiertos del Tribunal Superior Eleitoral, incluidas las elecciones suplementarias, con la persona identificada por el CPF validado (TSE, 2024). En las simulaciones, la identidad del líder es el par municipio-persona: quien fue alcalde en dos municipios cuenta como dos líderes, lo que evita que el agrupamiento global del paquete junte ciudades diferentes. Entran 5.468 municipios con alcalde identificado en los diez periodos y al menos dos alcaldes diferentes. Ningún resultado real entra en las simulaciones, con dos excepciones: el coeficiente del generador, calibrado a partir de un estadístico del índice real (Sección 4.3), y, en la Sección 5.3, la información de **qué** municipios-periodo tienen el índice observado.

4.3 El generador y las celdas

El ruido es autorregresivo de orden uno en el calendario, con coeficiente 0,217, y la laguna se impone después de generado el ruido. El ruido es gaussiano, estacionario desde el primer periodo (varianza 1 e innovaciones de varianza $1 - \rho^2$) e independiente entre municipios; en las celdas de potencia, cada persona recibe un efecto gaussiano de varianza Prop/(1 − Prop), el mismo a ambos lados de una laguna. El coeficiente es el del generador calibrado en el estudio prerregistrado: la autocorrelación medida en el índice real después de descontar municipio y periodo fue 0,084, valor sesgado a la baja por el descuento de la media en series cortas (Nickell, 1981), y 0,217 es el coeficiente autorregresivo cuya autocorrelación, medida con el mismo

descuento en series sintéticas de diez periodos, reproduce los 0,084 (método de los momentos, por bisección). Cada celda tiene 500 bases y 1.000 permutaciones por base; las tasas de rechazo al 5% se presentan con intervalos exactos del 95% (Clopper & Pearson, 1934). En cada celda, la submuestra de municipios y la posición de las lagunas se sortean una vez y quedan fijas en las 500 bases; los intervalos miden la incertidumbre de Monte Carlo dentro de ese diseño, no la variación entre submuestras o máscaras. Las celdas varían:

- la posición de la laguna: ninguna; el periodo 9 (primer medio mandato después de la elección de 2020, el mismo que falta en el Saeb de 2021); un periodo interior sorteado; un periodo vecino de un cambio; un periodo dentro de un mandato;
- el tratamiento: costura por defecto o `nostitch`;
- el número de municipios: submuestras aleatorias de 50, 200 y 1.000 y el panel completo;
- el coeficiente: 0,217 o 0;
- la presencia de efecto: sin efecto, o efecto por persona con el 10% o el 5% de la varianza, para medir la potencia.

Las celdas condicionadas a la posición de la laguna solo aceptan municipios en los que esa posición existe, y por eso tienen menos municipios que la submuestra de 1.000; la Tabla 1 presenta el número efectivo de cada una. Los controles de la misma muestra (sin laguna, en los mismos 867 municipios) y las celdas del `nostitch` en el panel completo se añadieron después de la revisión externa del texto: el módulo entró en la cadena de hash antes de su salida, y la regla de lectura se escribió en el prerregistro del artículo antes de ejecutar, pero fuera de cualquier cadena (Sección 4.4).

Tabla 1

Celdas de la traducción fiel del paquete: diseño y rechazo al 5% (500 bases, 1.000 permutaciones cada una)

Módulo	Municipios	Observaciones usadas	Laguna	Tratamiento	ρ	Efecto (Prop)	Rechazo (%)	IC exacto del 95% (%)
diagnostico_ado	1.000	10.000	ninguna	costura	0,217	0%	2,2	1,10 a 3,90
diagnostico_ado	1.000	9.000	periodo 9	costura	0,217	0%	27,2	23,34 a 31,33
diagnostico_ado	867	7.803	mitad de mandato	costura	0,217	0%	0,2	0,01 a 1,11
diagnostico_ado	1.000	9.000	periodo 9	costura	0,000	0%	6,4	4,42 a 8,92
diagnostico_ado	1.000	9.000	periodo 9	nostitch	0,217	0%	4,6	2,94 a 6,82
diagnostico_ado	869	7.821	sorteada, 2+ alcaldes/tramo	nostitch	0,217	0%	6,2	4,25 a 8,69
diagnostico_ado	1.000	10.000	ninguna	costura	0,217	10%	98,8	97,41 a 99,56
diagnostico_ado	867	7.803	mitad de mandato	costura	0,217	10%	96,8	94,86 a 98,16
diagnostico_ado_juizes	867	8.670	ninguna	costura	0,217	0%	2,2	1,10 a 3,90
diagnostico_ado_juizes	867	8.670	ninguna	costura	0,217	10%	99,0	97,68 a 99,67
diagnostico_ado_juizes	1.000	9.000	periodo 9	nostitch	0,217	10%	98,4	96,87 a 99,31
diagnostico_ado_juizes	869	7.821	sorteada, 2+ alcaldes/tramo	nostitch	0,217	10%	99,0	97,68 a 99,67
diagnostico_ado_juizes	1.000	10.000	ninguna	costura	0,217	5%	55,0	50,52 a 59,42
diagnostico_ado_juizes	1.000	9.000	periodo 9	nostitch	0,217	5%	61,0	56,57 a 65,30
diagnostico_ado_escala	5.468	—	periodo 9	costura	0,217	0%	76,6	72,64 a 80,24
diagnostico_ado_escala	5.468	—	junto a cambio de alcalde	costura	0,217	0%	89,4	86,36 a 91,96
diagnostico_ado_escala	5.468	—	interior sorteada	costura	0,217	0%	34,6	30,43 a 38,95
diagnostico_ado_juizes	5.468	54.680	ninguna	costura	0,217	0%	0,2	0,01 a 1,11
diagnostico_ado_juizes	5.468	49.212	periodo 9	nostitch	0,217	0%	1,6	0,69 a 3,13
diagnostico_ado_juizes	5.468	40.533	junto a cambio de alcalde	nostitch	0,217	0%	1,2	0,44 a 2,59
diagnostico_ado_juizes	5.468	42.972	interior sorteada	nostitch	0,217	0%	2,0	0,96 a 3,65
diagnostico_ado_mascara_real	1.854	—	máscara real, laguna interior	costura	0,217	0%	34,8	30,63 a 39,16
diagnostico_ado_mascara_real	1.854	—	máscara real, laguna interior	nostitch	0,217	0%	3,6	2,15 a 5,63
diagnostico_ado_mascara_real	707	—	máscara real, solo borde	costura	0,217	0%	3,8	2,30 a 5,87

Fuente: `results.json` del estudio (salidas con sha256 verificado). Municipio sin laguna: 10 observaciones. Las filas de la máscara real usan solo la información de qué municipios-periodo tienen el índice; el resultado es sintético. Efecto = fracción de la varianza debida al alcalde; 0% = nula verdadera. Observaciones usadas = municipios-periodo que entran en la prueba después de la laguna y, con `nostitch`, del descarte de tramos con un solo alcalde; no registrado (—) en las celdas de escala y de la máscara real. En las celdas con laguna en el periodo 9 y `nostitch`, las observaciones usadas incluyen el periodo 10, tramo de una fila que nunca se sortea y que no contribuye a la variación entre permutaciones cuando su alcalde no aparece en el otro tramo. Municipios = unidades que entran en la celda antes del descarte de tramos por `nostitch`.

4.4 Registro y revisión

Cada experimento se grabó en una cadena de hash antes de ejecutarse, y la tesis y el texto pasaron por revisores independientes. Los módulos, las semillas y las reglas de pasar o detenerse de los experimentos principales se registraron con SHA-256 antes de cada ejecución (las reglas de lectura de las celdas añadidas en la revisión quedaron fuera de la cadena, Sección 4.3), en cadenas encadenadas (`manifest.jsonl`) que el paquete de replicación publica (Flores, 2026); el encadenamiento garantiza la integridad y el orden de los registros, pero las marcas de tiempo provienen de la fecha de modificación de los archivos, sin sellado de tiempo externo, y por eso la anterioridad es declarada, no autenticada. Las pruebas de humo usaron semillas desechables declaradas en el propio registro. La tesis fue revisada por un consejo de modelos de lenguaje (uno de ellos encontró la opción `nostitch` en la ayuda del paquete, que la búsqueda anterior no había leído) y el texto, por tres modelos de lenguaje de familias diferentes, con la misma instrucción y sin ver el dictamen de los otros. Cada crítica recibió una respuesta registrada.

5. Resultados

5.1 Dónde cae la laguna decide

En la submuestra de mil municipios, la misma laguna corta lleva la prueba del 0,2% (867 municipios) al 27,2% de rechazo según la posición, frente al 2,2% sin laguna. La Figura 1 resume las celdas de la submuestra de 1.000 municipios, con el número efectivo de cada barra. Sin laguna, el paquete rechaza el 2,2% (intervalo del 1,10% al 3,90%), un conservadurismo leve del propio paquete cuya causa no se aisló: el valor p estricto no lo explicaría, y la candidata es el regreso de alcaldes al cargo (Sección 3.2). Con la laguna del periodo 9 cosida, el rechazo sube al

27,2% (del 23,34% al 31,33%). Con la laguna dentro de un mandato, en los 867 municipios que tienen un alcalde durante tres periodos seguidos, cae al 0,2%, frente al 2,2% sin laguna en esos mismos municipios.

El conservadurismo de la laguna dentro del mandato no borra la potencia. Con un efecto por persona del 10% de la varianza, en los mismos 867 municipios, la prueba detecta el efecto en el 96,8% de las bases con laguna dentro del mandato, frente al 99,0% sin laguna. La desviación en el sentido conservador pesa bajo la hipótesis nula y casi no pesa ante un efecto de ese tamaño.

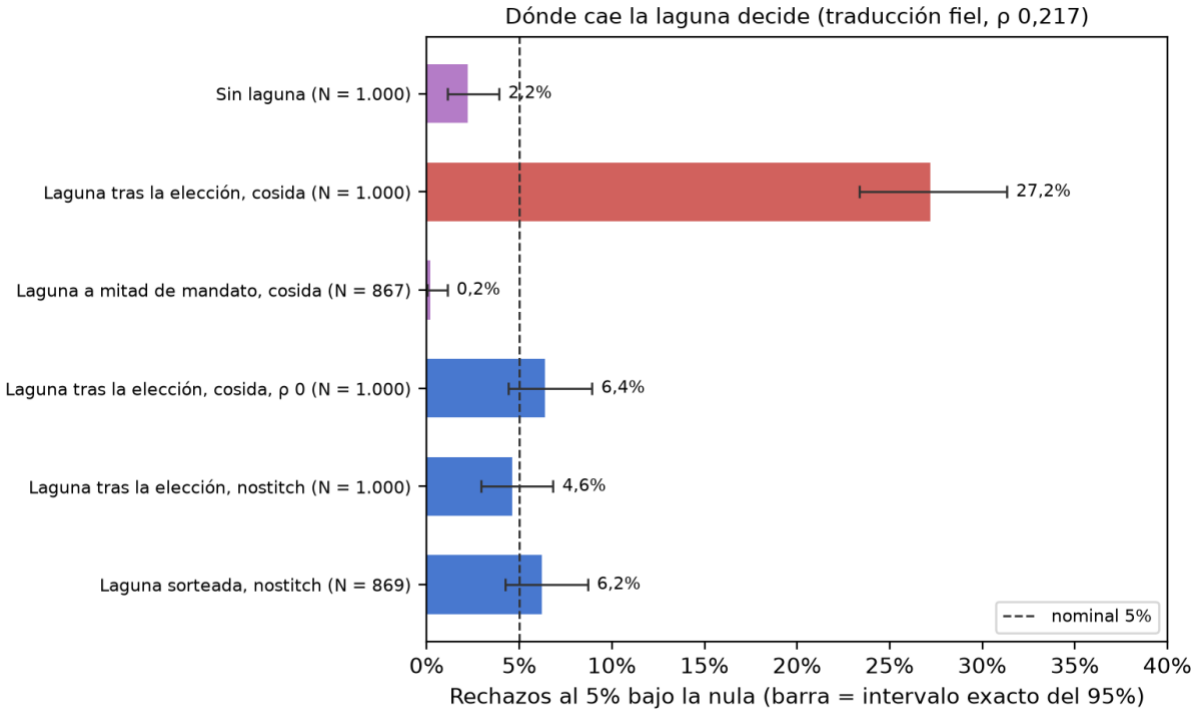
Sin correlación serial, desaparece el contraste de covarianzas de la Sección 3.2. Con $\rho = 0$ y la laguna del periodo 9, el rechazo es del 6,4%, compatible con el 5% con la precisión de 500 bases.

La opción que el paquete ya ofrece elimina la inflación de decenas de puntos en los casos probados. Con `nostitch`, la laguna del periodo 9 da un 4,6%, y una laguna interior sorteada, con dos o más alcaldes en los dos tramos, da un 6,2% (del 4,25% al 8,69%); ambas son compatibles con el 5% con la precisión de 500 bases, y el intervalo de la segunda no excluye una inflación de algunos puntos. La segunda celda reduce, sin excluirla, la sospecha de que el `nostitch` solo funcione por dejar tramos sin sorteo útil. Con efecto del alcalde, el `nostitch` detecta un 98,4% con el 10% de la varianza, frente al 98,8% sin laguna, y un 61,0% con el 5%, frente al 55,0% sin laguna; con la laguna sorteada de dos o más alcaldes por tramo y el 10% de la varianza, un 99,0%. Estas comparaciones tienen dos límites: en esas celdas el `nostitch` no descarta ningún tramo, y el control sin laguna ya rechaza menos bajo la hipótesis nula (2,2% frente a 4,6%). No se midió la potencia en las posiciones en las que el `nostitch` descarta tramos,

como la laguna vecina de un cambio (en el panel completo, el `nostitch` descarta el 17,6% de las celdas que quedan después de la laguna), ni en el panel de 5.468 municipios.

Figura 1

Rechazo bajo la hipótesis nula en la submuestra de 1.000 municipios (N efectivo en cada barra), según la posición de la laguna y el tratamiento (traducción fiel del paquete; barras: intervalo exacto del 95%)



5.2 El panel grande transforma un sesgo pequeño en un error sistemático

De 50 a 5.468 municipios, el rechazo con la laguna vecina de un cambio va del 6,8% al 89,4%. La Figura 2 muestra las tres posiciones de laguna bajo la costura por defecto. Con la laguna vecina de un cambio, el rechazo es del 6,8% con 50 municipios (del 4,75% al 9,37%, todavía compatible con el 5%), del 14,2% con 200, del 35,2% con 1.000 y del 89,4% con el panel completo. Con la laguna del periodo 9, los valores son 8,2%, 15,8%, 26,2% y 76,6%. Con una laguna interior sorteada, 7,8%, 7,6%, 14,4% y 34,6%.

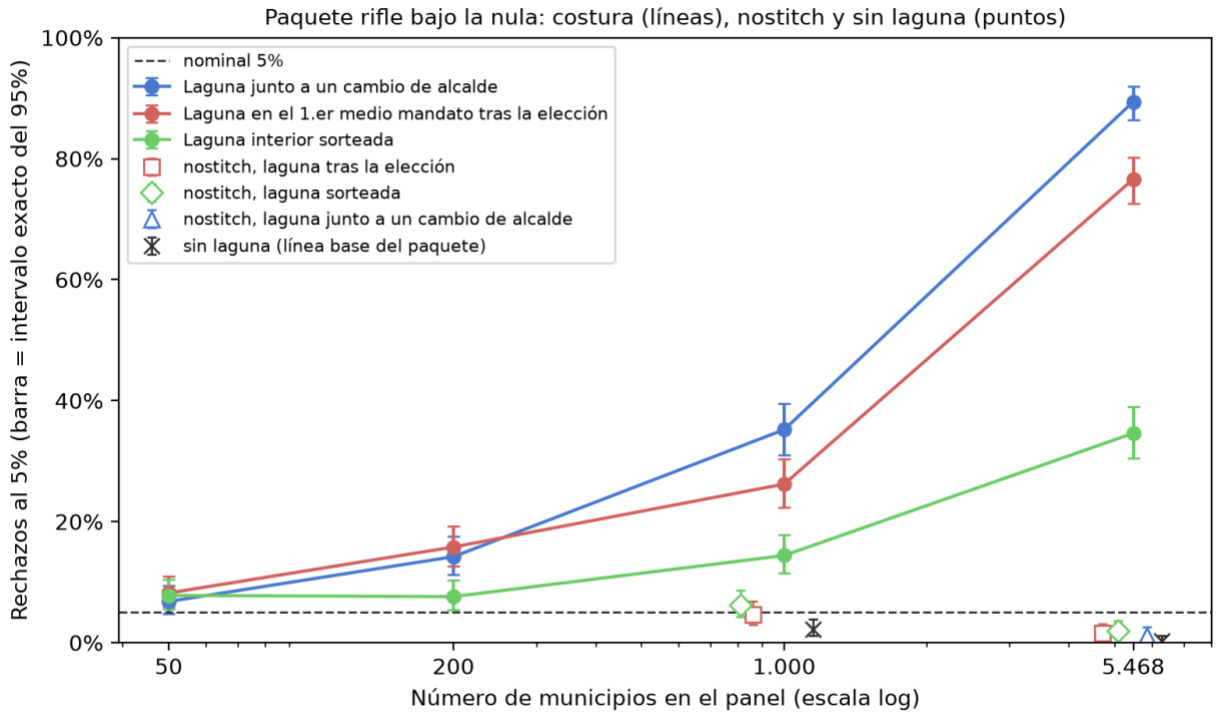
Una laguna de un solo periodo, sorteada, ya distorsiona. La ayuda del paquete dice que la costura es ventajosa cuando "a few years are missing idiosyncartically" [*sic*] ("faltan pocos años de forma idiosincrática"). En los mandatos municipales brasileños, el 70,1% de las lagunas sorteadas cae junto a un cambio de alcalde, y el rechazo en el panel completo llega al 34,6%. El caso en el que la ayuda ve ventaja en la costura no es seguro cuando los mandatos son cortos y el panel es grande. La fracción de lagunas vecinas de un cambio es un diagnóstico útil, pero no una regla suficiente: la magnitud depende también de la autocorrelación, de la duración de los mandatos, del regreso de líderes y del número de unidades.

El 26,2% con 1.000 municipios y laguna en el periodo 9 proviene de una submuestra y una semilla diferentes de las del 27,2% de la Sección 5.1. La celda del periodo 9 es una mezcla: en el 62,3% de los municipios la laguna separa a alcaldes diferentes y, en los demás, la misma persona está a ambos lados; el caso puro de laguna entre alcaldes diferentes es la celda vecina de un cambio, con el 89,4%.

En el panel completo, el `nostitch` elimina la inflación de decenas de puntos y deja una prueba conservadora. Sin ninguna laguna, el paquete rechaza el 0,2% con los 5.468 municipios, frente al 2,2% en la submuestra de 1.000; como el número de unidades y la composición cambian a la vez, y la causa del conservadurismo no se aisló, la comparación solo muestra que este es mayor en el panel completo. Con `nostitch`, las tres posiciones de laguna dan 1,6% (periodo 9), 1,2% (vecina de un cambio) y 2,0% (sorteada), frente al 76,6%, 89,4% y 34,6% con la costura. Ninguno de los tres intervalos contiene el 5%, y las tres estimaciones quedan por encima de la línea de base sin laguna, como las de 1.000 municipios (4,6% y 6,2% frente a 2,2%). Los datos no separan lo que proviene del conservadurismo del paquete de lo que proviene de los vínculos entre tramos de la Sección 6.1.

Figura 2

Costura por defecto del paquete (líneas): rechazo bajo la hipótesis nula por número de municipios y posición de la laguna; puntos: `nostitch` *y línea de base sin laguna, con 1.000 municipios (la laguna sorteada con* `nostitch` *usa 869 municipios con dos o más alcaldes en cada tramo) y en el panel completo (traducción fiel del paquete; eje horizontal en escala logarítmica, con los puntos ligeramente desplazados para que no se superpongan; barras: intervalo exacto del 95%)*



5.3 Las lagunas reales repiten el patrón

Con las lagunas que tiene el índice real, la costura rechaza el 34,8% y el `nostitch`, el 3,6%. Usando solo la información de qué municipios-periodo tienen índice observado en el estudio prerregistrado, y un resultado sintético, los 1.854 municipios con laguna interior rechazan el 34,8% bajo la costura (del 30,63% al 39,16%) y el 3,6% con `nostitch`. Los 707 municipios con laguna solo al comienzo o al final de la serie rechazan el 3,8% bajo la costura: una laguna de borde no empalma nada y no distorsiona.

5.4 El motor del estudio daba números mayores

El motor propio del estudio, que etiqueta cada periodo de mando de un alcalde como un grupo, dio rechazos mayores; el agrupamiento es una explicación posible, no aislada. En ese motor, las mismas celdas dan números mayores: 98,2% con la laguna del periodo 9 en el panel completo, 76,0% con la laguna sorteada y 71,4% con una laguna de dos periodos. La fusión de la misma persona a ambos lados de una laguna cosida ocurre en los dos códigos; solo el paquete junta en un mismo grupo a quien vuelve al cargo después de otro alcalde, pero los códigos también difieren en la comparación del valor p (mayor o igual en el motor, estrictamente mayor en el paquete) y en las semillas. La celda de dos periodos, que borra un mandato entero, no se usa como evidencia sobre la longitud. Los números principales de este artículo provienen del paquete; los del motor quedan como sensibilidad.

5.5 El caso que motivó la investigación

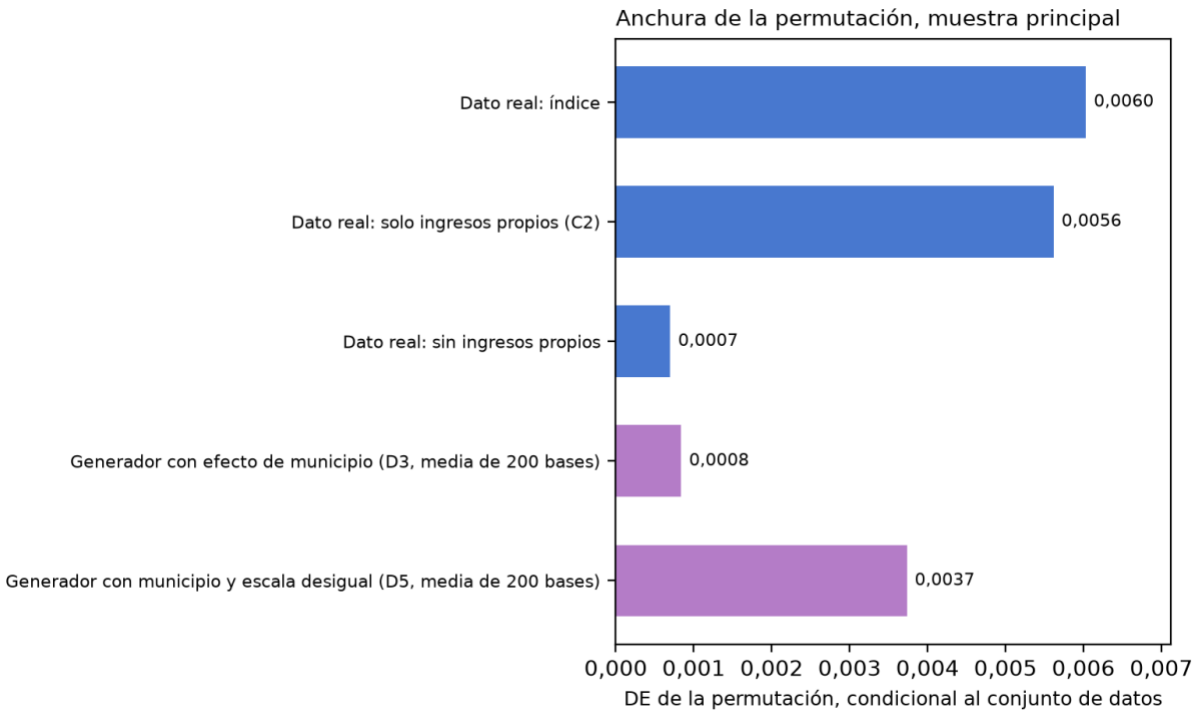
El estudio prerregistrado terminó sin evidencia de efecto del alcalde, y sin poder afirmar que el alcalde no importa. Rehecha con sorteo dentro de tramos continuos (análogo al `nostitch`, pero con cada periodo de mando del alcalde como grupo propio), con el tamaño confirmado en el 5,2% en una ronda predeclarada de 2.000 bases, la prueba se aplicó una única vez a los datos reales. El R^2 de los alcaldes verdaderos quedó por debajo de la media de los sorteos en las tres versiones prerregistradas, con valor p de 0,869 en la muestra principal, 0,488 con efecto rezagado y 0,904 en los municipios con 20 mil habitantes o más. La regla prerregistrada de equivalencia produjo “no importa”, pero una auditoría posterior al resultado mostró que el umbral de esa regla se había calibrado sin diferencias entre municipios, y el

registro final del estudio es: equivalencia no demostrada, conclusión no concluyente en cuanto a la exclusión de efectos relevantes.

La misma auditoría encontró que poquísimas series de ingresos propios dominan la distribución de la prueba, y parte de ellas era un error de declaración. La desviación estándar de la distribución de permutación en el dato real proviene casi por completo de los ingresos propios (Figura 3; contribuciones calculadas manteniendo fijo el denominador del índice completo): 0,0056 solo con ellos, frente a 0,0007 sin ellos, en un total de 0,0060. Entre las celdas más extremas había totales negativos de ingresos propios en 2024, un valor imposible: 34 municipios, 31 de ellos en Tocantins, con el IPTU declarado con signo negativo en la Declaração de Contas Anuais (Tesouro Nacional, 2025), con una mediana de cerca de 19,6 millones de reales negativos por municipio. Tratar esos valores como ausentes, por una regla grabada antes de volver a ejecutar, no cambió el resultado de la muestra principal, cuyo valor p quedó en 0,862. Cambió en una sensibilidad exploratoria, la que incluye periodos de mando de un único periodo: el valor p bajó de 0,129 a 0,028, por debajo del 5%. La regla prerregistrada de decisión mira la muestra principal; esa sensibilidad no altera la decisión confirmatoria y queda informada como señal exploratoria, que pide una investigación propia.

Figura 3

Anchura de la distribución de permutación en la muestra principal del estudio: dato real con y sin los ingresos propios, frente a dos generadores sintéticos (misma magnitud: desviación estándar condicional al conjunto de datos; las barras del dato real con y sin los ingresos propios mantienen fijo el denominador del índice completo)



5.6 La primera medida, en el diseño prerregistrado

El número que detuvo el estudio, 64%, es el tamaño de la prueba prerregistrada del proyecto, no el del paquete. En la fase piloto, con el motor del estudio, la costura en los municipios con laguna interior rechazó el 64,0% (del 56,93% al 70,65%) y en los municipios con laguna solo de borde, el 5,0%. Esa diferencia entre borde e interior fue la primera evidencia de que el problema estaba en el empalme. Con el paquete, el mismo conjunto de lagunas da un 34,8% (Sección 5.3). Las dos medidas son correctas, cada una para su procedimiento.

6. Discusión

6.1 Qué cambia para quien usa la prueba

En paneles con muchas unidades y lagunas en medio de la serie, la costura por defecto no debe usarse sin verificar el tamaño. La recomendación operativa que sostienen los resultados es preferir el `nostitch` cuando haya lagunas interiores, con la salvedad de que su costo en potencia solo se midió en celdas en las que no descarta tramos, y, en cualquier caso, informar tres números: la fracción de lagunas vecinas de un cambio de líder, la autocorrelación del residuo y el tamaño de la prueba en una simulación bajo la hipótesis nula con la estructura real de mandatos. Una laguna sistemática, como la de un examen suspendido durante la pandemia, puede ser más problemática cuando se alinea de la misma forma con los cambios en muchas unidades, caso que las celdas de este artículo no aíslan.

El `nostitch` no es una garantía universal. Eliminó la inflación de decenas de puntos en las celdas probadas (la del 6,2% no excluye algunos puntos), pero la traducción muestra que el paquete sigue agrupando a la misma persona entre tramos, lo que deja una covarianza residual de orden ρ^2 entre los dos lados de una laguna cuando el mismo líder gobierna en ambos. Lo mismo vale para el tramo de una fila que el paquete mantiene (el periodo 10, con la laguna en el 9): nunca se sortea, pero, cuando la misma persona aparece en los dos tramos, permanece en el grupo de esa persona en el otro tramo. Las celdas con `nostitch` quedan algunos puntos por encima de la línea de base sin laguna del paquete (Sección 5.2); esos vínculos son una explicación compatible, no aislada, y nada garantiza el mismo comportamiento en paneles con otra estructura.

6.2 Qué no cambia

Aquí no se reanalizó ningún resultado publicado de Berry y Fowler. Las simulaciones de tamaño del artículo original siguen siendo válidas para los diseños sin laguna que cubren. Un rechazo publicado solo puede haber sido inflado por este mecanismo si la muestra usada tenía lagunas interiores y correlación serial, y el sentido del efecto depende de dónde caían las lagunas respecto de las fronteras de los mandatos. En el código de replicación (Berry & Fowler, 2020), todas las llamadas de `rifle` que generan las Tablas 2 a 4 usan la costura por defecto, y las de gobernadores, alcaldes y CEO usan también la opción `growth`, que calcula la variación solo entre periodos consecutivos: un nivel faltante aislado en medio de la serie se convierte en una laguna de dos periodos en la serie de variaciones (un bloque de L niveles faltantes se convierte en $L + 1$ periodos ausentes), y la autocorrelación cambia al pasar de niveles a variaciones (la traducción de este artículo no implementa esa opción). Si esos paneles tienen lagunas interiores vecinas de cambios, y de qué tamaño son, no se verificó aquí; responder a eso exige reanalizar cada aplicación.

6.3 Límites

Los límites principales son el código traducido, el generador autorregresivo y una fuente no leída.

- La traducción del código se probó a mano, pero no se confrontó con Stata.
- El ruido sintético es autorregresivo de orden uno; otras estructuras de dependencia no se probaron en las celdas principales, aunque el estudio prerregistrado verificó el tamaño de la prueba por tramos bajo seis generadores alternativos: cinco quedaron entre el 4,6% y el 6,2%, y el no estacionario resultó conservador, en el 1,2%.

- La búsqueda en la literatura (OpenAlex, Semantic Scholar, Crossref, la primera página de Google Scholar, la ayuda y el código del paquete, el material suplementario y el código de replicación de Berry y Fowler) no encontró la distorsión documentada, con confianza media: Google Scholar bloqueó las páginas siguientes, y el texto completo de Smith y Gray (2021), la única extensión metodológica del RIFLE localizada, no se obtuvo: RePEc no registra restricción de descarga, pero la página de la editorial negó el acceso el 1 de noviembre de 2026, y una nueva búsqueda el 3 de noviembre, en 30 vías (editorial, agregadores de acceso abierto, repositorios y páginas de los autores), no encontró una versión abierta. Si aquella revalidación en series históricas trató las lagunas, la parte de este artículo que dice que el problema no estaba documentado cae; la cuantificación en este panel permanece, y la originalidad del diagnóstico dependerá de la comparación con aquel trabajo.
- La primera búsqueda no leyó la ayuda del paquete y dejó pasar el `nostitch`. El error se registró y se corrigió antes de la redacción.

7. Conclusión

Un periodo faltante en el lugar equivocado, repetido en muchos municipios, basta para que la prueba de liderazgo encuentre un alcalde que no existe. La costura de lagunas que describe el artículo original de Berry y Fowler (2021), y que el paquete oficial aplica por defecto, no produce este sesgo cuando la laguna queda en el borde de la serie o cuando el resultado no tiene correlación serial (con $\rho = 0$, la celda probada dio un tamaño compatible con el 5%). Cuando la laguna cae junto a un cambio, separando a alcaldes diferentes, y el resultado tiene una correlación modesta como la calibrada a partir del índice del estudio, la prueba rechaza en exceso

en paneles grandes: en la celda vecina de un cambio, 6,8% con 50 municipios (intervalo que todavía incluye el 5%), 14,2% con 200 y 89,4% con 5.468. Las lagunas dentro de un mandato pueden empujar el estadístico hacia cualquier lado, y el regreso del alcalde después de la laguna, en los casos calculados, hacia el lado conservador. El criterio explícito de la ayuda del paquete, una laguna larga u otra razón no especificada, no nombra la posición de la laguna respecto de los cambios, y es ella la que debe entrar en el diagnóstico. La corrección ya existe y es de los autores: la opción `nostitch`, que eliminó la inflación de decenas de puntos en las celdas probadas, con una potencia similar a la del control donde se midió (Sección 5.1). En el panel completo, deja la prueba conservadora, entre el 1,2% y el 2,0%, por encima del 0,2% del paquete sin laguna.

Quedan abiertas cuatro direcciones: (i) confrontar la traducción con el propio Stata, con el archivo `.do` que acompaña al paquete de replicación (Flores, 2026); (ii) medir, en los datos de replicación que Berry y Fowler publicaron y en otras aplicaciones, cuántas lagunas interiores caen junto a cambios de líder; (iii) aislar la causa del conservadurismo del paquete sin laguna, que es mayor en el panel completo sin que se hayan separado el número de unidades y la composición, y probar otras estructuras de dependencia y el efecto de los líderes que vuelven al cargo; (iv) evaluar una variante del `nostitch` que trate cada periodo de mando del líder como grupo propio, retirando de la suma explicada los términos que vinculan a la misma persona a través de la laguna (Sección 6.1).

Disponibilidad de datos y código

El código de las simulaciones, la traducción del `rifle.ado` con las pruebas, las salidas con hash y la cadena de procedencia están en el paquete de replicación de este artículo (Flores, 2026), en

el repositorio público https://github.com/ulissesflores/rifle-gap-bias y archivado en Zenodo con el DOI https://doi.org/10.5281/zenodo.24044367, con el código bajo la licencia Apache-2.0 y el texto y las figuras bajo la CC BY 4.0. El paquete de replicación también incluye un archivo `.do` para reproducir las celdas centrales en Stata y un panel anonimizado de mandatos (cada par de alcalde y municipio con un identificador único en el panel completo, sin CPF, porque el paquete agrupa a los líderes por el identificador en todas las unidades al mismo tiempo, y periodos numerados del 1 al 10, porque el `nostitch` reconoce la contigüidad por periodo más uno). Los datos de origen son públicos: TSE (2024), Inep (2024), Tesouro Nacional (2025) y Ministério da Saúde (2025).

Referencias

Akhtari, M., Moreira, D., & Trucco, L. (2022). Political turnover, bureaucratic turnover, and the quality of public services. *American Economic Review, 112*(2), 442-493. https://doi.org/10.1257/aer.20171867

Berry, C. R., & Fowler, A. (2018). *RIFLE: Stata module to perform randomization inference for leader effects* (Statistical Software Components S458461). Boston College Department of Economics. https://ideas.repec.org/c/boc/bocode/s458461.html

Berry, C. R., & Fowler, A. (2020). *Replication data for: Leadership or luck? Randomization inference for leader effects in politics, business, and sports* [Conjunto de datos y código, Stata 16.1; archivos fechados en noviembre de 2020]. https://voices.uchicago.edu/fowler/research

Berry, C. R., & Fowler, A. (2021). Leadership or luck? Randomization inference for leader effects in politics, business, and sports. *Science Advances, 7*(4), eabe3404. https://doi.org/10.1126/sciadv.abe3404

Brollo, F., & Nannicini, T. (2012). Tying your enemy's hands in close races: The politics of federal transfers in Brazil. *American Political Science Review, 106*(4), 742-761. https://doi.org/10.1017/S0003055412000433

Canay, I. A., Romano, J. P., & Shaikh, A. M. (2017). Randomization tests under an approximate symmetry assumption. *Econometrica, 85*(3), 1013-1030. https://doi.org/10.3982/ECTA13081

Clopper, C. J., & Pearson, E. S. (1934). The use of confidence or fiducial limits illustrated in the case of the binomial. *Biometrika, 26*(4), 404-413. https://doi.org/10.1093/biomet/26.4.404

Fitza, M. A. (2014). The use of variance decomposition in the investigation of CEO effects: How large must the CEO effect be to rule out chance? *Strategic Management Journal, 35*(12), 1839-1852. https://doi.org/10.1002/smj.2192

Flores, C. U. (2026). *Does a mayor improve a city beyond chance? Missing data at a change of mayor makes the test say yes: Replication package* (Versión 1.0.0) [Software y datos]. Codex Hash Research Laboratory. Zenodo. https://doi.org/10.5281/zenodo.24044367. Repositorio de código: https://github.com/ulissesflores/rifle-gap-bias

Inep. (2024). *Microdados e resultados do Saeb* [Conjunto de datos]. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. https://download.inep.gov.br

Jones, B. F., & Olken, B. A. (2005). Do leaders matter? National leadership and growth since World War II. *Quarterly Journal of Economics, 120*(3), 835-864. https://doi.org/10.1162/003355305774268165

Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics, 17*(3), 1217-1241. https://doi.org/10.1214/aos/1176347265

Lahiri, S. N. (2003). *Resampling methods for dependent data*. Springer. https://doi.org/10.1007/978-1-4757-3803-2

Lehmann, E. L., & Romano, J. P. (2005). *Testing statistical hypotheses* (3rd ed.). Springer. https://doi.org/10.1007/0-387-27605-X

Ministério da Saúde. (2025). *Sistema de Informações sobre Nascidos Vivos (Sinasc) e Sistema de Informações sobre Mortalidade (SIM)* [Conjunto de datos]. DataSUS. https://opendatasus.saude.gov.br

Nickell, S. (1981). Biases in dynamic models with fixed effects. *Econometrica, 49*(6), 1417-1426. https://doi.org/10.2307/1911408

Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences, 115*(11), 2600-2606. https://doi.org/10.1073/pnas.1708274114

Politis, D. N., & Romano, J. P. (1994). The stationary bootstrap. *Journal of the American Statistical Association, 89*(428), 1303-1313. https://doi.org/10.1080/01621459.1994.10476870

Quigley, T. J., & Graffin, S. D. (2017). Reaffirming the CEO effect is significant and much larger than chance: A comment on Fitza (2014). *Strategic Management Journal, 38*(3), 793-801. https://doi.org/10.1002/smj.2503

Smith, D. S., & Gray, T. R. (2021). Looking for leadership in historical context: An extension of the RIFLE method of randomization inference. *Journal of Historical Political Economy, 1*(2), 215-234. https://doi.org/10.1561/115.00000010

Tesouro Nacional. (2025). *Siconfi: Declaração de Contas Anuais (DCA), Anexo I-C, exercícios 2013 a 2024* [Conjunto de datos]. https://apidatalake.tesouro.gov.br/ords/siconfi/tt/dca

TSE. (2024). *Repositório de dados eleitorais: candidatos e resultados, 2004 a 2020* [Conjunto de datos]. Tribunal Superior Eleitoral. https://dadosabertos.tse.jus.br

Winkler, A. M., Ridgway, G. R., Webster, M. A., Smith, S. M., & Nichols, T. E. (2014). Permutation inference for the general linear model. *NeuroImage, 92*, 381-397. https://doi.org/10.1016/j.neuroimage.2014.01.060