CODEX HASH

RESEARCH LABORATORY

Il sindaco migliora la città oltre il caso? Un dato mancante al cambio di sindaco fa dire sì al test

Cucitura delle lacune, correlazione seriale e ampiezza del test di permutazione di Berry e Fowler in un panel di comuni brasiliani

Carlos Ulisses Flores

Codex Hash Research Laboratory

ORCID: 0000-0002-6034-7765

Data: 7 novembre 2026

Riassunto

Il test di inferenza per randomizzazione per gli effetti del leader (RIFLE) di Berry e Fowler (2021) confronta quanto i mandati veri spiegano un risultato con quanto lo spiegherebbero mandati della stessa durata in ordine sorteggiato, ed è diventato il modo diretto per chiedersi se un governante conti "oltre il caso". Per gli anni senza dati, l'articolo originale e l'opzione predefinita del pacchetto ufficiale per Stata (Berry & Fowler, 2018) scartano le osservazioni mancanti e cuciono i blocchi restanti in un tempo continuo. Questo articolo mostra che tale cucitura, sotto una correlazione seriale modesta, fa rilevare al test un effetto del leader inesistente quando, nel panel comunale esaminato, la lacuna cade accanto a un cambio di sindaco (il ritorno dello stesso sindaco dopo la lacuna può invertire l'effetto), e che l'entità dell'errore cresce con il numero di unità del panel. L'evidenza proviene da simulazioni sotto l'ipotesi nulla sulla struttura reale dei mandati di 5.468 comuni brasiliani (2005-2024), eseguite su una traduzione del percorso predefinito del codice ufficiale e registrate in una catena di hash prima di ogni esecuzione. Con una lacuna di un mezzo mandato subito dopo l'elezione (nel 62,3% dei 5.468 comuni essa separa sindaci diversi) e rumore autoregressivo di coefficiente 0,217, il rifiuto al 5% arriva al 76,6% nel panel intero e all'89,4% quando la lacuna è adiacente a un cambio; con 50 comuni varia dal 6,8% all'8,2%, e solo la cella adiacente al cambio è ancora compatibile con il 5%. Con la maschera reale di disponibilità dell'indice dello studio, il rifiuto è del 34,8%. Senza correlazione seriale, la lacuna del periodo 9 dà il 6,4%, compatibile con il 5%. Con l'opzione `nostitch` che lo stesso pacchetto offre, l'inflazione di decine di punti scompare: 4,6% con 1.000 comuni, 3,6% con la maschera reale e dall'1,2% al 2,0% nel panel intero, un test conservativo, benché al di sopra dello 0,2% che il pacchetto rifiuta senza alcuna lacuna; nelle celle da 1.000 comuni in cui è stata misurata la potenza, senza tratti scartati e senza eguagliare l'ampiezza dei

test, essa è risultata simile a quella del controllo senza lacuna. Con la lacuna a metà di un mandato lungo, il test è risultato conservativo, ma il segno dipende dalla posizione della lacuna rispetto ai confini dei mandati. L'help del pacchetto raccomanda di disattivare la cucitura in presenza di "una lacuna lunga" o di un'altra ragione che non specifica; i risultati indicano che la lunghezza non basta e che la posizione della lacuna rispetto al cambio di leader deve entrare nella diagnosi. L'articolo non afferma che alcun risultato pubblicato di Berry e Fowler sia sbagliato e non presenta la correzione come nuova: essa esiste già nel pacchetto. Il caso che ha motivato l'indagine, uno studio preregistrato sui sindaci brasiliani, si è concluso senza evidenza di un effetto del sindaco e con la conclusione di equivalenza non dimostrata.

Parole chiave: inferenza per randomizzazione; effetti del leader; dati mancanti; correlazione seriale; preregistrazione; sindaci

1. Introduzione

Chiedersi se un governante conta significa chiedersi se il risultato cambia con la persona, e il RIFLE lo verifica confrontando la storia reale con storie sorteggiate. Jones e Olken (2005) hanno mostrato che la morte di capi di Stato in carica altera la crescita, e hanno riacceso un filone che cerca di separare l'effetto della persona dall'effetto del contesto. Berry e Fowler (2021) hanno proposto una procedura più diretta per la domanda "oltre il caso": regredire il risultato su indicatori di leader, conservare l'R^2, e confrontarlo con la distribuzione dell'R^2 ottenuta quando l'ordine dei mandati di ciascuna unità viene rimescolato, mantenendo la durata di ciascuno. Se i mandati veri spiegano più di quasi tutti i sorteggi, l'ipotesi di effetto nullo viene rifiutata. Gli autori hanno applicato il test a capi di Stato, governatori e sindaci degli Stati Uniti, dirigenti d'impresa e allenatori sportivi, e lo hanno reso disponibile come modulo per Stata (Berry & Fowler, 2018). Questo articolo mostra che, quando mancano anni nel mezzo della serie, il modo predefinito di trattare la lacuna può far rilevare al test un leader che non esiste.

La procedura dipende da una scelta che sembra di retroscena: che cosa fare con gli anni senza dati. L'articolo originale è esplicito: "we drop those observations and stitch together blocks of time, coding a new time variable so that we have a single, contiguous stretch of time with complete data for each unit" (Berry & Fowler, 2021) ("scartiamo queste osservazioni e cuciamo insieme i blocchi di tempo, codificando una nuova variabile temporale in modo da avere un unico tratto continuo di dati completi per ciascuna unità"). Il pacchetto fa lo stesso per impostazione predefinita e offre l'opzione `nostitch`, descritta nell'help come quella da usare "if there is a long gap between periods or some other reason not to comprate [*sic*] observations across missing periods" (Berry & Fowler, 2018) ("se c'è una lacuna lunga tra i periodi o un'altra ragione per non confrontare osservazioni attraverso periodi mancanti"). Nessuna delle

simulazioni di ampiezza degli autori combina lacuna e correlazione seriale: quelle con 20 unità per 20 periodi, con peso 0 o 0,2 sul periodo precedente, non hanno lacune; quelle con cambio endogeno di leader, con il numero di unità e di periodi di ciascuna applicazione, concatenano il risultato simulato nell'ordine delle righe, ordinate secondo il calendario ma applicando la correlazione alla riga precedente anche quando l'anno salta, secondo il codice di replica (Berry & Fowler, 2020), e per questo non producono lo scollamento tra calendario e tempo cucito di cui tratta questo articolo; quelle di potenza, che con effetto zero misurano circa il 5% di rifiuto, usano rumore indipendente; e quelle del materiale supplementare trattano del costo di transizione in panel completi, senza correlazione seriale.

Questo articolo è nato da uno studio preregistrato che ha applicato il RIFLE ai sindaci brasiliani, con un indice di punteggio scolastico, entrate proprie e mortalità infantile, dal 2005 al 2024. Nella fase pilota, prima di qualsiasi calcolo con i sindaci veri, il test con la cucitura ha rifiutato l'ipotesi nulla vera nel 64,0% di 200 simulazioni nei comuni con lacuna interna, quando il valore corretto sarebbe stato il 5% (Sezione 5.6). Lo studio si è fermato ed è stato rifatto, e la domanda è diventata un'altra: che cosa, nella lacuna, inganna il test?

La risposta ha quattro parti, tutte misurate su una traduzione fedele del codice ufficiale:

1. **Nel panel comunale esaminato, la cucitura predefinita rifiuta troppo quando la lacuna cade accanto a un cambio di sindaco** e il risultato ha correlazione seriale positiva (Sezione 5.1); quando lo stesso sindaco ritorna dopo la lacuna, il segno può invertirsi (Sezione 3.2).
2. **La lunghezza della lacuna non basta a valutare il rischio.** Una lacuna breve, di un solo periodo per comune, può già distorcere sotto correlazione seriale, e il segno della

distorsione dipende da dove cade la lacuna rispetto ai confini dei mandati; nella cella testata, la lacuna a metà di un mandato lungo ha reso il test conservativo (Sezioni 3.2, 3.3 e 5.1).

3. **L'errore aumenta fortemente nei panel più grandi esaminati**: con 50 comuni varia dal 6,8% all'8,2% (solo la cella adiacente al cambio è ancora compatibile con il 5%) e arriva all'89,4% con 5.468 (Sezione 5.2).

4. **L'opzione `nostitch`, che esiste già nel pacchetto, elimina l'inflazione di decine di punti** nei casi testati; nel panel intero il test diventa conservativo, e la potenza, misurata solo con 1.000 comuni, è risultata simile a quella del controllo senza lacuna (Sezioni da 5.1 a 5.3).

L'help del pacchetto contiene già l'opzione che restringe il sorteggio a tratti continui; le parti da 1 a 3 e la misura della parte 4 non si trovano nell'articolo originale, nel suo materiale supplementare, nel codice di replica degli autori né nell'help, e non sono state individuate nelle altre fonti esaminate (Sezione 6.3). L'articolo non rivendica la correzione, che è degli autori; rivendica la misura del problema, gli esempi di cambiamento di segno e una diagnosi per decidere quando usarla. Non afferma neppure che alcun risultato pubblicato di Berry e Fowler sia sbagliato (Sezione 6.2).

2. Lavori correlati

La domanda sui leader è già stata posta molte volte; nelle fonti esaminate non abbiamo individuato una misura dell'ampiezza del test quando mancano dati nel mezzo della serie. La scomposizione della varianza per leader ha una storia di controversia su quanto l'"effetto dell'esecutivo" superi il caso. Il disegno di Jones e Olken identifica l'effetto attraverso pochi

cambi inattesi, 57 in un panel di 130 paesi dal 1945 secondo Berry e Fowler (2021), e il RIFLE usa tutti i cambi. Fitza (2014) ha mostrato che buona parte della varianza attribuita agli amministratori delegati poteva essere riprodotta dalla fortuna; Quigley e Graffin (2017) hanno risposto che l'effetto è significativo e maggiore del caso. Il RIFLE (Berry & Fowler, 2021) ha trasformato questa discussione in un test di permutazione con una regola di decisione chiara, e Smith e Gray (2021) lo hanno esteso a serie storiche lunghe e lo hanno riconvalidato su dati simulati. Dei 42 record che citano Berry e Fowler in OpenAlex (31 ottobre 2026; alcuni sono versioni di uno stesso lavoro), nessun titolo menziona lacune né l'ampiezza del test; il filtraggio è debole e non ha recuperato Smith e Gray. Questo articolo ha letto solo il riassunto di tale estensione, che non menziona lacune; poiché le serie storiche hanno spesso anni mancanti, il testo completo potrebbe trattare il problema (vedi Sezione 6.3).

La validità di un test di permutazione deriva dalla simmetria dei dati sotto l'ipotesi nulla, non dall'ipotesi nulla in sé. Lehmann e Romano (2005) presentano il risultato classico: il test è esatto quando la distribuzione congiunta dei dati è invariante rispetto al gruppo di permutazioni usato. Winkler et al. (2014) discutono che cosa accade quando questa scambiabilità vale solo a blocchi e perché possano essere necessarie restrizioni al sorteggio. Canay, Romano e Shaikh (2017) trattano test di randomizzazione sotto simmetria solo approssimata. La lezione comune è che "effetto del leader nullo" non implica, da solo, che tutti gli ordini di mandato siano ugualmente probabili; ciò dipende dalla struttura di dipendenza del risultato, ed è esattamente questa struttura che la cucitura altera.

Ricampionare dati dipendenti richiede di preservare la dipendenza che conta. La letteratura sul bootstrap a blocchi (Künsch, 1989; Politis & Romano, 1994; Lahiri, 2003) mostra che blocchi contigui preservano la dipendenza locale di serie stazionarie e che le giunzioni tra

blocchi sono proprio il punto in cui questa dipendenza smette di essere riprodotta; il bootstrap stazionario unisce i blocchi di proposito e resta consistente, perché tratta le giunzioni come parte del disegno. Il RIFLE non è un bootstrap e le giustificazioni sono diverse, ma il principio si trasferisce: riordinare blocchi in un indice temporale che non corrisponde al calendario confronta partizioni sotto covarianze che non sono quelle che i dati hanno.

In Brasile, la domanda sui sindaci è stata posta con altri disegni. Akhtari, Moreira e Trucco (2022) hanno mostrato, con elezioni decise di stretta misura, che il cambio di partito alla guida del comune cambia dirigenti scolastici e insegnanti e riduce i voti degli alunni; Brollo e Nannicini (2012) hanno mostrato che i sindaci allineati al presidente ricevono più trasferimenti discrezionali per infrastrutture negli anni preelettorali, motivo per cui lo studio preregistrato ha rimosso dal risultato l'effetto dell'allineamento partitico. Secondo la ricognizione fatta per questo articolo (Sezione 6.3), il RIFLE non era stato applicato ai sindaci brasiliani, con la fiducia media lì dichiarata. Lo studio ha seguito la logica di preregistrazione difesa da Nosek et al. (2018): regole di decisione registrate prima dei dati, emendamenti datati e nulla scartato dopo aver visto il risultato.

3. La procedura, la cucitura e il meccanismo

3.1 Il RIFLE e che cosa fa la cucitura

Il test confronta una partizione reale con partizioni sorteggiate, e la cucitura cambia quali partizioni sono possibili. Per ogni unità m con periodi $t = 1, \ldots, T$, il risultato y viene residualizzato rispetto agli effetti di periodo. L'R^2 reale viene dalla regressione sugli indicatori di leader; ogni permutazione sorteggia l'ordine dei mandati dell'unità, mantenendone la durata, e

ricalcola l'R^2. Il valore p è la frazione di permutazioni con R^2 maggiore di quello reale. Nel codice ufficiale (`rifle.ado`, Berry & Fowler, 2018), qui contano tre dettagli:

- il risultato viene residualizzato per periodo prima di scartare i mancanti, il che, per un risultato mancante, equivale a sottrarre la media del periodo nelle celle osservate;
- gli indicatori sono dell'**identità** del leader (`absorb(leader)`), così che la stessa persona in due mandati separati forma un unico gruppo;
- il mandato ("stint") cambia quando cambia il leader, nell'ordine del tempo rinumerato, così che la stessa persona da entrambi i lati di una lacuna cucita diventa un unico mandato.

Con la cucitura, il periodo dopo la lacuna diventa adiacente, nell'indice temporale, al periodo prima di essa. Con `nostitch`, ogni tratto continuo di periodi osservati diventa un'unità di sorteggio a sé, e il tratto con un solo leader e due o più righe esce dal campione.

3.2 Due leader bastano per vedere il meccanismo

La covarianza tra due periodi resta quella del calendario, non quella dell'indice cucito. Sia il risultato, sotto l'ipotesi nulla, un processo autoregressivo stazionario con varianza σ^2 e covarianza $\sigma^2\rho^{|t-s|}$ tra i periodi t e s del calendario, con $0 < \rho < 1$. Per una partizione G in gruppi g di dimensione n_g, la somma dei quadrati spiegata è, a meno di un termine comune a tutte le partizioni,

$$Q = \sum_{g} \frac{1}{n_g} \left(\sum_{t \in g} y_t \right)^2 , \tag{1}$$

e il denominatore dell'R^2 è lo stesso in tutte le permutazioni di una stessa base. Ordinare l'R^2 equivale quindi a ordinare Q, il cui valore atteso è

$$\mathrm{E}[Q] = \sum_{g} \frac{1}{n_g} \sum_{t,s \in g} \sigma^2 \, \rho^{|t-s|}. \tag{2}$$

Si considerino sei periodi con il leader A in 1-2 e B in 3-6, e l'unico riordinamento possibile, B prima di A.

- **Lacuna adiacente al cambio** (manca il periodo 3): la partizione reale è {1, 2} | {4, 5, 6}; quella invertita, nella sequenza cucita, è {1, 2, 4} | {5, 6}. La partizione invertita mette la lacuna dentro un gruppo, dove essa riduce la covarianza interna. Indicando con Q_{inv} il valore dell'ordine invertito, risulta

$$\mathrm{E}[Q_{\mathrm{real}} - Q_{\mathrm{inv}}] = \frac{2}{3}\sigma^2(\rho - \rho^3) > 0, \tag{3}$$

  e l'adattamento reale risulta favorito senza alcun effetto del leader.

- **Lacuna dentro il mandato** (manca il periodo 4): la partizione reale è {1, 2} | {3, 5, 6}, e quella invertita {1, 2, 3} | {5, 6}. I ruoli si scambiano:

$$\mathrm{E}[Q_{\mathrm{real}} - Q_{\mathrm{inv}}] = -\frac{2}{3}\sigma^2(\rho - \rho^3) < 0, \tag{4}$$

  e la differenza media va in senso conservativo, a favore del sorteggio.

- **Lacuna dentro il mandato che comunque gonfia** (controesempio della revisione esterna): con A in 1-4, B in 5-6 e il periodo 2 mancante, la partizione reale è {1, 3, 4} | {5, 6} e quella invertita {1, 3} | {4, 5, 6}. Allora

$$\mathrm{E}[Q_{\mathrm{real}} - Q_{\mathrm{inv}}] = \frac{1}{3}\sigma^2\rho(1-\rho)(1-2\rho), \tag{5}$$

positivo per $\rho < 0{,}5$ (circa $0{,}032\sigma^2$ con $\rho = 0{,}217$). La lacuna è dentro il mandato di A, e l'adattamento reale risulta favorito.

- **Lacuna adiacente al cambio con differenza media negativa** (secondo controesempio della revisione esterna): con A in 1-2, B in 3-4, A di nuovo in 5-6 e il periodo 3 mancante, il pacchetto sorteggia tre permanenze e riunisce le due di A in un unico gruppo; la media sui sei ordini dà

$$\mathrm{E}[Q_{\mathrm{real}} - Q_{\mathrm{perm}}] = -\frac{1}{6}\sigma^2\rho^2(1-\rho)(2\rho^2 + 4\rho + 3), \tag{6}$$

circa $-0{,}024\sigma^2$ con $\rho = 0{,}217$. In questo caso il ritorno di A sposta già la statistica in senso conservativo anche senza alcuna lacuna (circa $-0{,}102\sigma^2$ con i sei periodi completi, con la stessa enumerazione), perché le due permanenze di A non sono mai adiacenti nei dati reali e lo diventano in quattro dei sei ordini; la lacuna riduce questo spostamento, ma non lo inverte. È la stessa candidata a causa del conservatorismo del pacchetto senza lacuna (Sezione 5.1).

Gli esempi usano la covarianza del calendario prima della sottrazione della media del periodo, che il test effettua; con maschere diverse tra comuni, questa sottrazione cambia la matrice di covarianza e collega le unità, così che il passaggio dagli esempi al panel è un argomento euristico, e le simulazioni applicano la sottrazione esattamente. Con $\rho = 0$ i quattro contrasti scompaiono. Il segno dipende quindi da come la lacuna si colloca rispetto ai confini dei gruppi reali e di quelli sorteggiati, compresi i gruppi che riuniscono un leader che ritorna, e non solo dal suo trovarsi accanto a un cambio o dentro un mandato. Questi segni sono di differenze medie,

non di tassi di rifiuto: in un panel di due comuni con la struttura del secondo esempio, la differenza media è negativa e, ciononostante, il test rifiuta nel 48,1% di 4.000 basi (l'ordine reale ha R^2 maggiore di quello invertito nel 47,3% di 400 mila basi, con rumore gaussiano e la sottrazione della media del periodo), perché i residui dei due comuni sono opposti, i tre ordini che non sono quello reale stanno dallo stesso lato di esso, e il valore p esatto, contando solo gli ordini strettamente maggiori, è 0 o 0,75; con 200 sorteggi, la stima oscilla attorno a questi due poli. Questa patologia di panel minuscoli con coda in senso stretto esiste anche senza lacuna e senza correlazione seriale, e non è il meccanismo della cucitura. La derivazione è stata proposta dalla revisione esterna di questo lavoro (Sezione 4.4); i tassi di rifiuto sono stati misurati per simulazione.

3.3 Perché il panel grande amplifica e la lunghezza non decide

Lo spostamento per unità è piccolo, ma si somma; la dispersione del test cresce più lentamente. Se lo spostamento medio per comune nella differenza tra la somma dei quadrati spiegata reale e quella permutata ha segno definito nell'insieme del panel, positivo quando prevalgono lacune adiacenti a cambi senza ritorno del leader, la somma su N unità indipendenti cresce con N, mentre la sua dispersione sotto l'ipotesi nulla cresce approssimativamente con $\sqrt{N}$. Nell'R^2, che divide le due somme per la somma dei quadrati totale, anch'essa proporzionale a N, lo spostamento resta di ordine costante e la dispersione cala con $1/\sqrt{N}$; il rapporto tra i due cresce con $\sqrt{N}$ in entrambi i casi. Per questo lo stesso bias per unità è quasi invisibile con 50 unità e decisivo con migliaia; nelle simulazioni, ogni dimensione usa un altro sottocampione, e la crescita concorda con il meccanismo senza isolarlo. La lunghezza della lacuna entra nella covarianza persa (la coppia unita passa da ρ a ρ^{L+1}), ma non decide il segno: la stessa lacuna

breve sposta la statistica a favore dell'adattamento reale quando separa due leader diversi che non ritornano, può spostarla in entrambe le direzioni quando sta dentro un mandato e, nei casi di ritorno calcolati qui, la sposta in senso conservativo, secondo i confini della Sezione 3.2.

4. Dati e disegno delle simulazioni

4.1 La traduzione del codice ufficiale e il suo limite

I numeri principali vengono da una traduzione in Python del percorso predefinito del `rifle.ado` distribuito su SSC (la versione con le opzioni `controls` e `notrend`; la copia `RIFLE.do` del codice di replica non le ha, ma cucitura e `nostitch` sono identici), perché non era disponibile Stata; questo è il limite principale dell'articolo. La traduzione copre l'R^2 senza controlli, la cucitura e il `nostitch`; non implementa le opzioni `controls`, `growth` e `notrend`, e presuppone che solo il risultato abbia valori mancanti (unità, leader e periodo sempre presenti, come nelle simulazioni). Essa riproduce i passaggi citati nella Sezione 3.1, con la riga corrispondente del codice annotata (`code/rifle_ado.py` nel pacchetto di replica; Flores, 2026). È stata verificata contro calcoli fatti a mano in panel piccoli (tre test che coprono cucitura, fusione della stessa persona e regole del `nostitch`), contro l'enumerazione esatta dei 36 ordini di permanenze in un panel di due unità con un leader che ritorna (il valore p del sorteggio dà 0,1103 con 200 mila permutazioni, contro 0,1111 esatto), contro la stessa enumerazione in un panel con `nostitch`, tratto scartato, tratto di una riga e la stessa persona nei due tratti (0,7511 contro 0,75 esatto), contro una ricostruzione indipendente della media che include la riga reale (uguale fino alla 12ª cifra decimale e diversa dalla media senza di essa) e contro il motore proprio dello studio in un panel senza ritorno di sindaco, dove i due coincidono nel valore registrato nella catena (R^2 di 0,4777757). Ciò non sostituisce un confronto con Stata, che il

pacchetto di replica lascia predisposto nel file `stata/rifle_celulas.do` per chi lo possieda (Sezione 7).

4.2 La struttura dei mandati

La struttura è reale; il risultato è sintetico. I sindaci di ciascun mezzo mandato (dieci periodi di due anni, 2005-2024) sono stati identificati a partire dai dati aperti del Tribunal Superior Eleitoral, comprese le elezioni suppletive, con la persona identificata dal CPF convalidato (TSE, 2024). Nelle simulazioni, l'identità del leader è la coppia comune-persona: chi è stato sindaco in due comuni conta come due leader, il che evita che il raggruppamento globale del pacchetto unisca città diverse. Entrano 5.468 comuni con sindaco identificato nei dieci periodi e almeno due sindaci diversi. Nessun risultato reale entra nelle simulazioni, con due eccezioni: il coefficiente del generatore, calibrato a partire da una statistica dell'indice reale (Sezione 4.3), e, nella Sezione 5.3, l'informazione su **quali** comuni-periodo hanno l'indice osservato.

4.3 Il generatore e le celle

Il rumore è autoregressivo di ordine uno nel calendario, con coefficiente 0,217, e la lacuna viene imposta dopo la generazione del rumore. Il rumore è gaussiano, stazionario fin dal primo periodo (varianza 1 e innovazioni di varianza $1 - \rho^2$) e indipendente tra comuni; nelle celle di potenza, ogni persona riceve un effetto gaussiano di varianza Prop/(1 − Prop), lo stesso da entrambi i lati di una lacuna. Il coefficiente è quello del generatore calibrato nello studio preregistrato: l'autocorrelazione misurata nell'indice reale dopo aver sottratto comune e periodo era 0,084, valore distorto verso il basso dalla sottrazione della media in serie brevi (Nickell, 1981), e 0,217 è il coefficiente autoregressivo la cui autocorrelazione, misurata con la stessa sottrazione in serie sintetiche di dieci periodi, riproduce lo 0,084 (metodo dei momenti, per

bisezione). Ogni cella ha 500 basi e 1.000 permutazioni per base; i tassi di rifiuto al 5% sono accompagnati da intervalli esatti al 95% (Clopper & Pearson, 1934). In ogni cella, il sottocampione di comuni e la posizione delle lacune vengono sorteggiati una volta e restano fissi nelle 500 basi; gli intervalli misurano l'incertezza Monte Carlo all'interno di questo disegno, non la variazione tra sottocampioni o maschere. Le celle variano:

- la posizione della lacuna: nessuna; il periodo 9 (primo mezzo mandato dopo l'elezione del 2020, lo stesso che manca nel Saeb del 2021); un periodo interno sorteggiato; un periodo adiacente a un cambio; un periodo dentro un mandato;
- il trattamento: cucitura predefinita o `nostitch`;
- il numero di comuni: sottocampioni casuali di 50, 200 e 1.000 e il panel intero;
- il coefficiente: 0,217 o 0;
- la presenza di effetto: nessun effetto, o effetto per persona pari al 10% o al 5% della varianza, per misurare la potenza.

Le celle condizionate alla posizione della lacuna accettano solo comuni in cui tale posizione esiste, e per questo hanno meno comuni del sottocampione di 1.000; la Tabella 1 riporta il numero effettivo di ciascuna. I controlli dello stesso campione (senza lacuna, negli stessi 867 comuni) e le celle del `nostitch` nel panel intero sono stati aggiunti dopo la revisione esterna del testo: il modulo è entrato nella catena di hash prima del suo output, e la regola di lettura è stata scritta nella preregistrazione dell'articolo prima dell'esecuzione, ma fuori da qualsiasi catena (Sezione 4.4).

Tabella 1

Celle della traduzione fedele del pacchetto: disegno e rifiuto al 5% (500 basi, 1.000 permutazioni ciascuna)

Modulo	Comuni	Osservazioni usate	Lacuna	Trattamento	ρ	Effetto (Prop)	Rifiuto (%)	IC esatto al 95% (%)
diagnostico_ado	1.000	10.000	nessuna	cucitura	0,217	0%	2,2	1,10 a 3,90
diagnostico_ado	1.000	9.000	periodo 9	cucitura	0,217	0%	27,2	23,34 a 31,33
diagnostico_ado	867	7.803	metà mandato	cucitura	0,217	0%	0,2	0,01 a 1,11
diagnostico_ado	1.000	9.000	periodo 9	cucitura	0,000	0%	6,4	4,42 a 8,92
diagnostico_ado	1.000	9.000	periodo 9	nostitch	0,217	0%	4,6	2,94 a 6,82
diagnostico_ado	869	7.821	sorteggiata, 2+ sindaci/tratto	nostitch	0,217	0%	6,2	4,25 a 8,69
diagnostico_ado	1.000	10.000	nessuna	cucitura	0,217	10%	98,8	97,41 a 99,56
diagnostico_ado	867	7.803	metà mandato	cucitura	0,217	10%	96,8	94,86 a 98,16
diagnostico_ado_juizes	867	8.670	nessuna	cucitura	0,217	0%	2,2	1,10 a 3,90
diagnostico_ado_juizes	867	8.670	nessuna	cucitura	0,217	10%	99,0	97,68 a 99,67
diagnostico_ado_juizes	1.000	9.000	periodo 9	nostitch	0,217	10%	98,4	96,87 a 99,31
diagnostico_ado_juizes	869	7.821	sorteggiata, 2+ sindaci/tratto	nostitch	0,217	10%	99,0	97,68 a 99,67
diagnostico_ado_juizes	1.000	10.000	nessuna	cucitura	0,217	5%	55,0	50,52 a 59,42
diagnostico_ado_juizes	1.000	9.000	periodo 9	nostitch	0,217	5%	61,0	56,57 a 65,30
diagnostico_ado_escala	5.468	—	periodo 9	cucitura	0,217	0%	76,6	72,64 a 80,24
diagnostico_ado_escala	5.468	—	accanto a cambio di sindaco	cucitura	0,217	0%	89,4	86,36 a 91,96
diagnostico_ado_escala	5.468	—	interna sorteggiata	cucitura	0,217	0%	34,6	30,43 a 38,95
diagnostico_ado_juizes	5.468	54.680	nessuna	cucitura	0,217	0%	0,2	0,01 a 1,11
diagnostico_ado_juizes	5.468	49.212	periodo 9	nostitch	0,217	0%	1,6	0,69 a 3,13
diagnostico_ado_juizes	5.468	40.533	accanto a cambio di sindaco	nostitch	0,217	0%	1,2	0,44 a 2,59
diagnostico_ado_juizes	5.468	42.972	interna sorteggiata	nostitch	0,217	0%	2,0	0,96 a 3,65
diagnostico_ado_mascara_real	1.854	—	maschera reale, lacuna interna	cucitura	0,217	0%	34,8	30,63 a 39,16
diagnostico_ado_mascara_real	1.854	—	maschera reale, lacuna interna	nostitch	0,217	0%	3,6	2,15 a 5,63
diagnostico_ado_mascara_real	707	—	maschera reale, solo bordo	cucitura	0,217	0%	3,8	2,30 a 5,87

Fonte: `results.json` dello studio (output con sha256 verificato). Comune senza lacuna: 10 osservazioni. Le righe della maschera reale usano solo l'informazione su quali comune-periodi hanno l'indice; il risultato è sintetico. Effetto = quota della varianza dovuta al sindaco; 0% = nulla vera. Osservazioni usate = comune-periodi che entrano nel test dopo la lacuna e, con `nostitch`, dopo lo scarto dei tratti con un solo sindaco; non registrato (—) nelle celle di scala e della maschera reale. Nelle celle con lacuna nel periodo 9 e `nostitch`, le osservazioni usate includono il periodo 10, tratto di una riga che non viene mai sorteggiato e che non contribuisce alla variazione tra le permutazioni quando il suo sindaco non compare nell'altro tratto. Comuni = unità che entrano nella cella prima dello scarto dei tratti da parte di `nostitch`.

4.4 Registrazione e revisione

Ogni esperimento è stato registrato in una catena di hash prima dell'esecuzione, e la tesi e il testo sono passati per revisori indipendenti. I moduli, i semi e le regole di proseguire o fermarsi degli esperimenti principali sono stati registrati con SHA-256 prima di ogni esecuzione (le regole di lettura delle celle aggiunte in revisione sono rimaste fuori dalla catena, Sezione 4.3), in catene concatenate (`manifest.jsonl`) che il pacchetto di replica pubblica (Flores, 2026); la concatenazione garantisce l'integrità e l'ordine delle registrazioni, ma le marche temporali provengono dalla data di modifica dei file, senza marca temporale esterna, e per questo l'anteriorità è dichiarata, non autenticata. Gli smoke test hanno usato semi usa e getta dichiarati nella registrazione stessa. La tesi è stata rivista da un consiglio di modelli linguistici (uno di essi ha trovato l'opzione `nostitch` nell'help del pacchetto, che la ricerca precedente non aveva letto) e il testo da tre modelli linguistici di famiglie diverse, con la stessa istruzione e senza che ciascuno vedesse il parere degli altri. Ogni critica ha ricevuto una risposta registrata.

5. Risultati

5.1 Dove cade la lacuna è decisivo

Nel sottocampione di mille comuni, la stessa lacuna breve porta il test dallo 0,2% (867 comuni) al 27,2% di rifiuto a seconda della posizione, contro il 2,2% senza lacuna. La Figura 1 riassume le celle del sottocampione di 1.000 comuni, con il numero effettivo di ogni barra. Senza lacuna, il pacchetto rifiuta il 2,2% (intervallo dall'1,10% al 3,90%), un lieve conservatorismo del pacchetto stesso la cui causa non è stata isolata: il valore p stretto non lo spiegherebbe, e la candidata è il ritorno in carica di sindaci (Sezione 3.2). Con la lacuna del periodo 9 cucita, il rifiuto sale al 27,2% (dal 23,34% al 31,33%). Con la lacuna dentro un

mandato, negli 867 comuni che hanno un sindaco per tre periodi consecutivi, scende allo 0,2%, contro il 2,2% senza lacuna in questi stessi comuni.

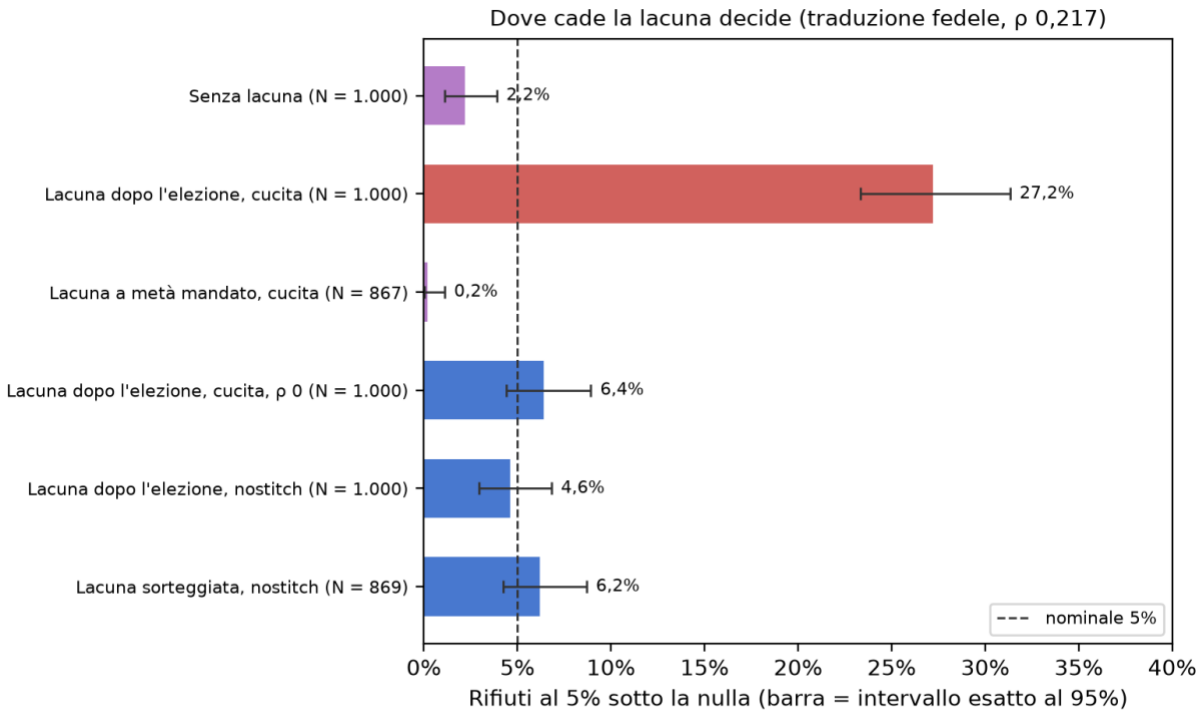
Il conservatorismo della lacuna dentro il mandato non annulla la potenza. Con un effetto per persona del 10% della varianza, negli stessi 867 comuni, il test rileva l'effetto nel 96,8% delle basi con lacuna dentro il mandato, contro il 99,0% senza lacuna. La deviazione in senso conservativo pesa sotto l'ipotesi nulla e quasi non pesa di fronte a un effetto di questa entità.

Senza correlazione seriale, scompare il contrasto di covarianze della Sezione 3.2. Con $\rho = 0$ e la lacuna del periodo 9, il rifiuto è del 6,4%, compatibile con il 5% alla precisione di 500 basi.

L'opzione che il pacchetto già offre elimina l'inflazione di decine di punti nei casi testati. Con `nostitch`, la lacuna del periodo 9 dà il 4,6%, e una lacuna interna sorteggiata, con due o più sindaci nei due tratti, dà il 6,2% (dal 4,25% all'8,69%); entrambe sono compatibili con il 5% alla precisione di 500 basi, e l'intervallo della seconda non esclude un'inflazione di alcuni punti. La seconda cella riduce, senza escluderlo, il sospetto che il `nostitch` funzioni solo perché lascia tratti senza sorteggio utile. Con effetto del sindaco, il `nostitch` rileva il 98,4% con il 10% della varianza, contro il 98,8% senza lacuna, e il 61,0% con il 5%, contro il 55,0% senza lacuna; con la lacuna sorteggiata con due o più sindaci per tratto e il 10% della varianza, il 99,0%. Questi confronti hanno due limiti: in queste celle il `nostitch` non scarta alcun tratto, e il controllo senza lacuna rifiuta già meno sotto l'ipotesi nulla (2,2% contro 4,6%). La potenza nelle posizioni in cui il `nostitch` scarta tratti, come la lacuna adiacente al cambio (nel panel intero, il `nostitch` scarta il 17,6% delle celle che restano dopo la lacuna), e nel panel di 5.468 comuni non è stata misurata.

Figura 1

Rifiuto sotto l'ipotesi nulla nel sottocampione di 1.000 comuni (N effettivo in ogni barra), secondo la posizione della lacuna e il trattamento (traduzione fedele del pacchetto; barre: intervallo esatto al 95%)



5.2 Il panel grande trasforma un bias piccolo in un errore sistematico

Da 50 a 5.468 comuni, il rifiuto con la lacuna adiacente al cambio va dal 6,8% all'89,4%. La Figura 2 mostra le tre posizioni di lacuna sotto la cucitura predefinita. Con la lacuna adiacente al cambio, il rifiuto è del 6,8% con 50 comuni (dal 4,75% al 9,37%, ancora compatibile con il 5%), del 14,2% con 200, del 35,2% con 1.000 e dell'89,4% con il panel intero. Con la lacuna del periodo 9, i valori sono 8,2%, 15,8%, 26,2% e 76,6%. Con una lacuna interna sorteggiata, 7,8%, 7,6%, 14,4% e 34,6%.

Una lacuna di un solo periodo, sorteggiata, distorce già. L'help del pacchetto dice che la cucitura è vantaggiosa quando "a few years are missing idiosyncartically" [*sic*] ("mancano pochi

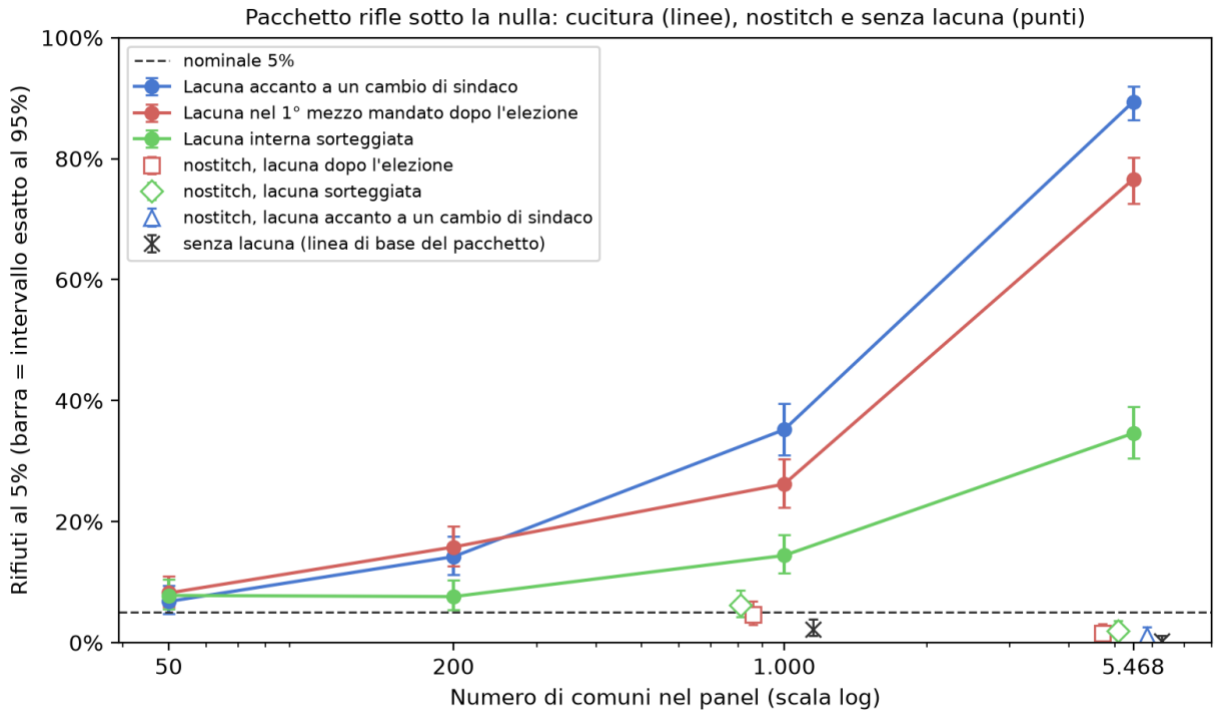
anni in modo idiosincratico"). Nei mandati comunali brasiliani, il 70,1% delle lacune sorteggiate cade accanto a un cambio di sindaco, e il rifiuto nel panel intero arriva al 34,6%. Il caso in cui l'help vede un vantaggio nella cucitura non è sicuro quando i mandati sono brevi e il panel è grande. La frazione di lacune adiacenti a cambi è una diagnosi utile, ma non una regola sufficiente: l'entità dipende anche dall'autocorrelazione, dalla durata dei mandati, dal ritorno dei leader e dal numero di unità.

Il 26,2% con 1.000 comuni e lacuna nel periodo 9 viene da un sottocampione e da un seme diversi da quelli del 27,2% della Sezione 5.1. La cella del periodo 9 è una miscela: nel 62,3% dei comuni la lacuna separa sindaci diversi e, negli altri, la stessa persona sta da entrambi i lati; il caso puro di lacuna tra sindaci diversi è la cella adiacente al cambio, con l'89,4%.

Nel panel intero, il `nostitch` elimina l'inflazione di decine di punti e lascia un test conservativo. Senza alcuna lacuna, il pacchetto rifiuta lo 0,2% con i 5.468 comuni, contro il 2,2% nel sottocampione di 1.000; poiché il numero di unità e la composizione cambiano insieme, e la causa del conservatorismo non è stata isolata, il confronto mostra solo che esso è maggiore nel panel intero. Con `nostitch`, le tre posizioni di lacuna danno 1,6% (periodo 9), 1,2% (adiacente al cambio) e 2,0% (sorteggiata), contro 76,6%, 89,4% e 34,6% con la cucitura. Nessuno dei tre intervalli contiene il 5%, e le tre stime restano al di sopra della linea di base senza lacuna, come quelle con 1.000 comuni (4,6% e 6,2% contro 2,2%). I dati non separano ciò che deriva dal conservatorismo del pacchetto da ciò che deriva dai collegamenti tra tratti della Sezione 6.1.

Figura 2

Cucitura predefinita del pacchetto (linee): rifiuto sotto l'ipotesi nulla per numero di comuni e posizione della lacuna; punti: `nostitch` *e linea di base senza lacuna, con 1.000 comuni (la lacuna sorteggiata con* `nostitch` *usa 869 comuni con due o più sindaci in ciascun tratto) e nel panel intero (traduzione fedele del pacchetto; asse orizzontale in scala logaritmica, con i punti leggermente spostati per non sovrapporsi; barre: intervallo esatto al 95%)*



5.3 Le lacune reali ripetono lo schema

Con le lacune che l'indice reale ha, la cucitura rifiuta il 34,8% e il `nostitch` il 3,6%. Usando solo l'informazione su quali comuni-periodo hanno l'indice osservato nello studio preregistrato, e un risultato sintetico, i 1.854 comuni con lacuna interna rifiutano il 34,8% sotto la cucitura (dal 30,63% al 39,16%) e il 3,6% con `nostitch`. I 707 comuni con lacuna solo all'inizio o alla fine della serie rifiutano il 3,8% sotto la cucitura: una lacuna di bordo non unisce nulla e non distorce.

5.4 Il motore dello studio dava numeri maggiori

Il motore proprio dello studio, che etichetta ogni permanenza di un sindaco come un gruppo, ha dato rifiuti maggiori; il raggruppamento è una spiegazione possibile, non isolata. In questo motore, le stesse celle danno numeri maggiori: 98,2% con la lacuna del periodo 9 nel panel intero, 76,0% con la lacuna sorteggiata e 71,4% con una lacuna di due periodi. La fusione della stessa persona da entrambi i lati di una lacuna cucita avviene in entrambi i codici; solo il pacchetto riunisce in uno stesso gruppo chi ritorna in carica dopo un altro sindaco, ma i codici differiscono anche nel confronto del valore p (maggiore o uguale nel motore, strettamente maggiore nel pacchetto) e nei semi. La cella di due periodi, che cancella un mandato intero, non è usata come evidenza sulla lunghezza. I numeri principali di questo articolo vengono dal pacchetto; quelli del motore restano come sensibilità.

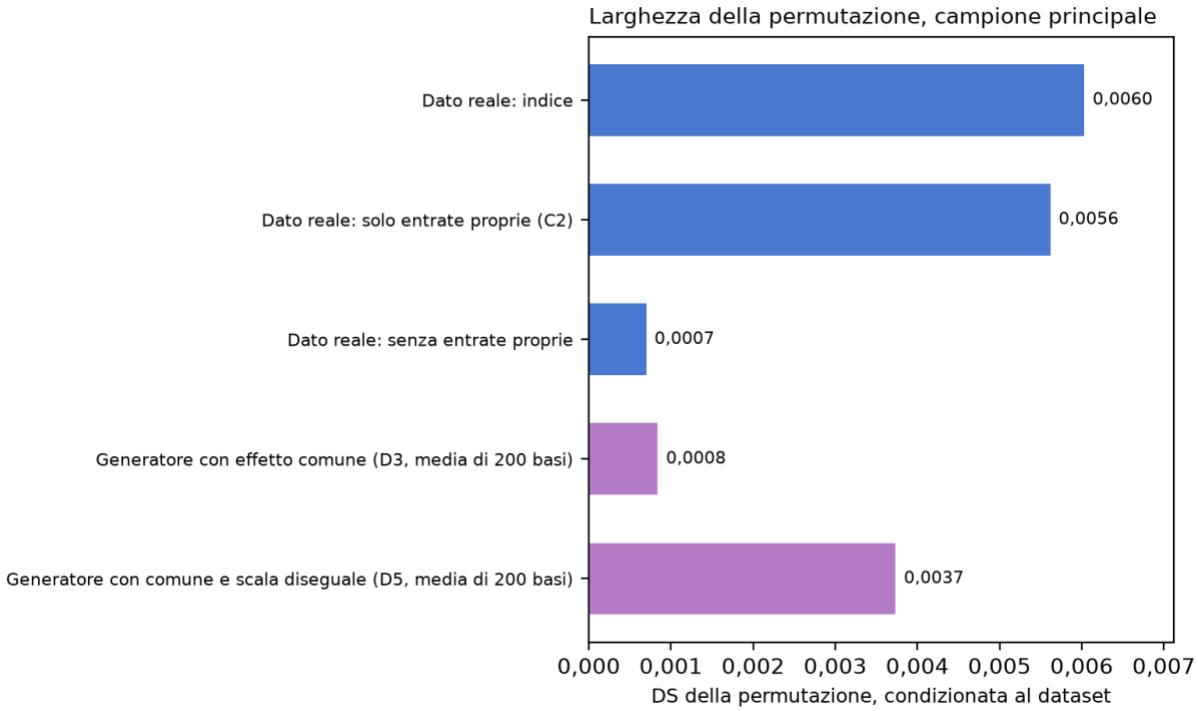
5.5 Il caso che ha motivato l'indagine

Lo studio preregistrato si è concluso senza evidenza di un effetto del sindaco, e senza poter affermare che il sindaco non conti. Rifatto con sorteggio all'interno di tratti continui (analogo al `nostitch`, ma con ogni permanenza del sindaco come gruppo a sé), con ampiezza confermata al 5,2% in una tornata predichiarata di 2.000 basi, il test è stato applicato una sola volta ai dati reali. L'R^2 dei sindaci veri è rimasto al di sotto della media dei sorteggi nelle tre versioni preregistrate, con valore p di 0,869 nel campione principale, 0,488 con effetto ritardato e 0,904 nei comuni con 20 mila abitanti o più. La regola preregistrata di equivalenza ha prodotto "non conta", ma un audit successivo al risultato ha mostrato che la soglia di tale regola era stata calibrata senza differenze tra comuni, e la registrazione finale dello studio è: equivalenza non dimostrata, conclusione inconcludente quanto all'esclusione di effetti rilevanti.

Lo stesso audit ha rilevato che pochissime serie di entrate proprie dominano la distribuzione del test, e una parte di esse era un errore di dichiarazione. La deviazione standard della distribuzione di permutazione nel dato reale proviene quasi tutta dalle entrate proprie (Figura 3; contributi calcolati mantenendo fisso il denominatore dell'indice completo): 0,0056 con esse soltanto, contro 0,0007 senza di esse, su un totale di 0,0060. Tra le celle più estreme c'erano totali negativi di entrate proprie nel 2024, valore impossibile: 34 comuni, 31 dei quali nel Tocantins, con l'IPTU dichiarato con segno negativo nella Declaração de Contas Anuais (Tesouro Nacional, 2025), con una mediana di circa 19,6 milioni di reais negativi per comune. Trattare questi valori come mancanti, per una regola registrata prima di rieseguire il test, non ha cambiato il risultato del campione principale, il cui valore p è rimasto a 0,862. Lo ha cambiato in una sensibilità esplorativa, quella che include permanenze di un solo periodo: il valore p è sceso da 0,129 a 0,028, sotto il 5%. La regola preregistrata di decisione guarda il campione principale; questa sensibilità non altera la decisione confermativa ed è riportata come segnale esplorativo, che richiede un'indagine propria.

Figura 3

Larghezza della distribuzione di permutazione nel campione principale dello studio: dato reale con e senza le entrate proprie, contro due generatori sintetici (stessa grandezza: deviazione standard condizionata all'insieme di dati; le barre del dato reale con e senza le entrate proprie mantengono fisso il denominatore dell'indice completo)



5.6 La prima misura, nel disegno preregistrato

Il numero che ha fermato lo studio, il 64%, è l'ampiezza del test preregistrato del progetto, non quella del pacchetto. Nella fase pilota, con il motore dello studio, la cucitura nei comuni con lacuna interna ha rifiutato il 64,0% (dal 56,93% al 70,65%) e nei comuni con lacuna solo di bordo il 5,0%. Questa differenza tra bordo e interno è stata la prima evidenza che il problema stava nella giunzione. Con il pacchetto, lo stesso insieme di lacune dà il 34,8% (Sezione 5.3). Le due misure sono corrette, ciascuna per la propria procedura.

6. Discussione

6.1 Che cosa cambia per chi usa il test

In panel con molte unità e lacune nel mezzo della serie, la cucitura predefinita non dovrebbe essere usata senza verificare l'ampiezza. La raccomandazione operativa che i risultati sostengono è preferire il `nostitch` quando ci sono lacune interne, con la riserva che il suo costo in potenza è stato misurato solo in celle in cui esso non scarta tratti, e, in ogni caso, riportare tre numeri: la frazione di lacune adiacenti a cambi di leader, l'autocorrelazione del residuo e l'ampiezza del test in una simulazione sotto l'ipotesi nulla con la struttura reale dei mandati. Una lacuna sistematica, come quella di una prova sospesa durante la pandemia, può essere più problematica quando si allinea allo stesso modo ai cambi in molte unità, caso che le celle di questo articolo non isolano.

Il `nostitch` non è una garanzia universale. Ha eliminato l'inflazione di decine di punti nelle celle testate (quella del 6,2% non esclude alcuni punti), ma la traduzione mostra che il pacchetto continua a raggruppare la stessa persona tra tratti, il che lascia una covarianza residua di ordine ρ^2 tra i due lati di una lacuna quando lo stesso leader governa entrambi. Lo stesso vale per il tratto di una riga che il pacchetto mantiene (il periodo 10, con la lacuna nel 9): non viene mai sorteggiato, ma, quando la stessa persona compare nei due tratti, resta nel suo gruppo nell'altro tratto. Le celle con `nostitch` restano alcuni punti al di sopra della linea di base senza lacuna del pacchetto (Sezione 5.2); questi collegamenti sono una spiegazione compatibile, non isolata, e nulla garantisce lo stesso comportamento in panel con un'altra struttura.

6.2 Che cosa non cambia

Nessun risultato pubblicato di Berry e Fowler è stato rianalizzato qui. Le simulazioni di ampiezza dell'articolo originale restano valide per i disegni senza lacuna che coprono. Un rifiuto pubblicato può essere stato gonfiato da questo meccanismo solo se il campione usato aveva lacune interne e correlazione seriale, e il senso dell'effetto dipende da dove le lacune cadevano rispetto ai confini dei mandati. Nel codice di replica (Berry & Fowler, 2020), tutte le chiamate di `rifle` che generano le Tabelle da 2 a 4 usano la cucitura predefinita, e quelle di governatori, sindaci e CEO usano anche l'opzione `growth`, che calcola la variazione solo tra periodi consecutivi: un livello mancante isolato nel mezzo della serie diventa una lacuna di due periodi nella serie delle variazioni (un blocco di L livelli mancanti diventa $L + 1$ periodi assenti), e l'autocorrelazione cambia passando dai livelli alle variazioni (la traduzione di questo articolo non implementa questa opzione). Se quei panel abbiano lacune interne adiacenti a cambi, e di quale entità, non è stato verificato qui; rispondere richiede di rianalizzare ogni applicazione.

6.3 Limiti

I limiti principali sono il codice tradotto, il generatore autoregressivo e una fonte non letta.

- La traduzione del codice è stata testata a mano, ma non confrontata con Stata.
- Il rumore sintetico è autoregressivo di ordine uno; altre strutture di dipendenza non sono state testate nelle celle principali, sebbene lo studio preregistrato abbia verificato l'ampiezza del test per tratti sotto sei generatori alternativi: cinque sono risultati tra il 4,6% e il 6,2%, e quello non stazionario è risultato conservativo, all'1,2%.
- La ricognizione della letteratura (OpenAlex, Semantic Scholar, Crossref, la prima pagina di Google Scholar, l'help e il codice del pacchetto, il materiale supplementare e il codice

di replica di Berry e Fowler) non ha trovato la distorsione documentata, con fiducia media: Google Scholar ha bloccato le pagine successive, e il testo completo di Smith e Gray (2021), l'unica estensione metodologica del RIFLE individuata, non è stato ottenuto: RePEc non registra restrizioni al download, ma la pagina dell'editore ha negato l'accesso il 1º novembre 2026, e una nuova ricerca il 3 novembre, su 30 canali (editore, aggregatori ad accesso aperto, repository e pagine degli autori), non ha trovato una versione aperta. Se quella riconvalida su serie storiche ha trattato le lacune, la parte di questo articolo che afferma che il problema non era documentato cade; la quantificazione in questo panel rimane, e l'originalità della diagnosi dipenderà dal confronto con quel lavoro.

- La prima ricognizione non ha letto l'help del pacchetto e si è lasciata sfuggire il `nostitch`. L'errore è stato registrato e corretto prima della stesura.

7. Conclusione

Un periodo mancante nel posto sbagliato, ripetuto in molti comuni, basta perché il test di leadership trovi un sindaco che non esiste. La cucitura delle lacune che l'articolo originale di Berry e Fowler (2021) descrive, e che il pacchetto ufficiale applica per impostazione predefinita, non produce questo bias quando la lacuna sta al bordo della serie o quando il risultato non ha correlazione seriale (con $\rho = 0$, la cella testata ha dato un'ampiezza compatibile con il 5%). Quando la lacuna cade accanto a un cambio, separando sindaci diversi, e il risultato ha una correlazione modesta come quella calibrata a partire dall'indice dello studio, il test rifiuta troppo nei panel grandi: nella cella adiacente al cambio, 6,8% con 50 comuni (intervallo che include ancora il 5%), 14,2% con 200 e 89,4% con 5.468. Le lacune dentro un mandato possono spingere

la statistica in entrambe le direzioni, e il ritorno del sindaco dopo la lacuna, nei casi calcolati, verso il lato conservativo. Il criterio esplicito dell'help del pacchetto, una lacuna lunga o un'altra ragione non specificata, non nomina la posizione della lacuna rispetto ai cambi, ed è questa che deve entrare nella diagnosi. La correzione esiste già ed è degli autori: l'opzione `nostitch`, che ha eliminato l'inflazione di decine di punti nelle celle testate, con potenza simile a quella del controllo dove è stata misurata (Sezione 5.1). Nel panel intero, essa rende il test conservativo, tra l'1,2% e il 2,0%, al di sopra dello 0,2% del pacchetto senza lacuna.

Quattro direzioni restano aperte: (i) confrontare la traduzione con Stata stesso, con il file `.do` che accompagna il pacchetto di replica (Flores, 2026); (ii) misurare, nei dati di replica che Berry e Fowler hanno pubblicato e in altre applicazioni, quante lacune interne cadono accanto a cambi di leader; (iii) isolare la causa del conservatorismo del pacchetto senza lacuna, che è maggiore nel panel intero senza che numero di unità e composizione siano stati separati, e testare altre strutture di dipendenza e l'effetto dei leader che ritornano in carica; (iv) valutare una variante del `nostitch` che tratti ogni permanenza del leader come gruppo a sé, togliendo dalla somma spiegata i termini che collegano la stessa persona attraverso la lacuna (Sezione 6.1).

Disponibilità di dati e codice

Il codice delle simulazioni, la traduzione del `rifle.ado` con i test, gli output con hash e la catena di provenienza si trovano nel pacchetto di replica di questo articolo (Flores, 2026), nel repository pubblico https://github.com/ulissesflores/rifle-gap-bias e archiviato su Zenodo con il DOI https://doi.org/10.5281/zenodo.24044367, con il codice sotto licenza Apache-2.0 e il testo e le figure sotto licenza CC BY 4.0. Il pacchetto di replica contiene anche un file `.do` per riprodurre le celle centrali in Stata e un panel anonimizzato dei mandati (ogni coppia di sindaco e comune

con un identificatore univoco nell'intero panel, senza CPF, perché il pacchetto raggruppa i leader per identificatore in tutte le unità contemporaneamente, e periodi numerati da 1 a 10, perché il `nostitch` riconosce la contiguità come periodo più uno). I dati di origine sono pubblici: TSE (2024), Inep (2024), Tesouro Nacional (2025) e Ministério da Saúde (2025).

Riferimenti bibliografici

Akhtari, M., Moreira, D., & Trucco, L. (2022). Political turnover, bureaucratic turnover, and the quality of public services. *American Economic Review, 112*(2), 442-493. https://doi.org/10.1257/aer.20171867

Berry, C. R., & Fowler, A. (2018). *RIFLE: Stata module to perform randomization inference for leader effects* (Statistical Software Components S458461). Boston College Department of Economics. https://ideas.repec.org/c/boc/bocode/s458461.html

Berry, C. R., & Fowler, A. (2020). *Replication data for: Leadership or luck? Randomization inference for leader effects in politics, business, and sports* [Set di dati e codice, Stata 16.1; file datati novembre 2020]. https://voices.uchicago.edu/fowler/research

Berry, C. R., & Fowler, A. (2021). Leadership or luck? Randomization inference for leader effects in politics, business, and sports. *Science Advances, 7*(4), eabe3404. https://doi.org/10.1126/sciadv.abe3404

Brollo, F., & Nannicini, T. (2012). Tying your enemy's hands in close races: The politics of federal transfers in Brazil. *American Political Science Review, 106*(4), 742-761. https://doi.org/10.1017/S0003055412000433

Canay, I. A., Romano, J. P., & Shaikh, A. M. (2017). Randomization tests under an approximate symmetry assumption. *Econometrica, 85*(3), 1013-1030. https://doi.org/10.3982/ECTA13081

Clopper, C. J., & Pearson, E. S. (1934). The use of confidence or fiducial limits illustrated in the case of the binomial. *Biometrika, 26*(4), 404-413. https://doi.org/10.1093/biomet/26.4.404

Fitza, M. A. (2014). The use of variance decomposition in the investigation of CEO effects: How large must the CEO effect be to rule out chance? *Strategic Management Journal, 35*(12), 1839-1852. https://doi.org/10.1002/smj.2192

Flores, C. U. (2026). *Does a mayor improve a city beyond chance? Missing data at a change of mayor makes the test say yes: Replication package* (Versione 1.0.0) [Software e dati]. Codex Hash Research Laboratory. Zenodo. https://doi.org/10.5281/zenodo.24044367. Repository del codice: https://github.com/ulissesflores/rifle-gap-bias

Inep. (2024). *Microdados e resultados do Saeb* [Set di dati]. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. https://download.inep.gov.br

Jones, B. F., & Olken, B. A. (2005). Do leaders matter? National leadership and growth since World War II. *Quarterly Journal of Economics, 120*(3), 835-864. https://doi.org/10.1162/003355305774268165

Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics, 17*(3), 1217-1241. https://doi.org/10.1214/aos/1176347265

Lahiri, S. N. (2003). *Resampling methods for dependent data*. Springer. https://doi.org/10.1007/978-1-4757-3803-2

Lehmann, E. L., & Romano, J. P. (2005). *Testing statistical hypotheses* (3rd ed.). Springer. https://doi.org/10.1007/0-387-27605-X

Ministério da Saúde. (2025). *Sistema de Informações sobre Nascidos Vivos (Sinasc) e Sistema de Informações sobre Mortalidade (SIM)* [Set di dati]. DataSUS. https://opendatasus.saude.gov.br

Nickell, S. (1981). Biases in dynamic models with fixed effects. *Econometrica, 49*(6), 1417-1426. https://doi.org/10.2307/1911408

Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences, 115*(11), 2600-2606. https://doi.org/10.1073/pnas.1708274114

Politis, D. N., & Romano, J. P. (1994). The stationary bootstrap. *Journal of the American Statistical Association, 89*(428), 1303-1313. https://doi.org/10.1080/01621459.1994.10476870

Quigley, T. J., & Graffin, S. D. (2017). Reaffirming the CEO effect is significant and much larger than chance: A comment on Fitza (2014). *Strategic Management Journal, 38*(3), 793-801. https://doi.org/10.1002/smj.2503

Smith, D. S., & Gray, T. R. (2021). Looking for leadership in historical context: An extension of the RIFLE method of randomization inference. *Journal of Historical Political Economy, 1*(2), 215-234. https://doi.org/10.1561/115.00000010

Tesouro Nacional. (2025). *Siconfi: Declaração de Contas Anuais (DCA), Anexo I-C, exercícios 2013 a 2024* [Set di dati]. https://apidatalake.tesouro.gov.br/ords/siconfi/tt/dca

TSE. (2024). *Repositório de dados eleitorais: candidatos e resultados, 2004 a 2020* [Set di dati]. Tribunal Superior Eleitoral. https://dadosabertos.tse.jus.br

Winkler, A. M., Ridgway, G. R., Webster, M. A., Smith, S. M., & Nichols, T. E. (2014). Permutation inference for the general linear model. *NeuroImage, 92*, 381-397. https://doi.org/10.1016/j.neuroimage.2014.01.060