CODEX HASH

RESEARCH LABORATORY

O prefeito melhora a cidade além do acaso? Dado faltando na troca de prefeito faz o teste dizer que sim

Costura de lacunas, correlação serial e o tamanho do teste de permutação de Berry e Fowler num painel de municípios brasileiros

Carlos Ulisses Flores

Codex Hash Research Laboratory

ORCID: 0000-0002-6034-7765

Data: 7 de novembro de 2026

Resumo

O teste de inferência por aleatorização para efeitos de líder (RIFLE) de Berry e Fowler (2021) compara o quanto os mandatos verdadeiros explicam um resultado com o quanto explicariam mandatos de mesma duração em ordem sorteada, e tornou-se a forma direta de perguntar se um governante importa "além do acaso". Para anos sem dado, o artigo original e a opção padrão do pacote oficial para Stata (Berry & Fowler, 2018) descartam as observações faltantes e costuram os blocos restantes num tempo contínuo. Este artigo mostra que essa costura, sob correlação serial modesta, faz o teste acusar efeito de líder inexistente quando, no painel municipal examinado, a lacuna cai junto de uma troca de prefeito (o retorno do mesmo prefeito depois da lacuna pode inverter o efeito), e que a magnitude do erro cresce com o número de unidades do painel. A evidência vem de simulações sob o nulo sobre a estrutura real de mandatos de 5.468 municípios brasileiros (2005-2024), rodadas numa tradução do caminho padrão do código oficial e registradas numa cadeia de hash antes de cada execução. Com uma lacuna de um meio-mandato logo após a eleição (em 62,3% dos 5.468 municípios ela separa prefeitos diferentes) e ruído autorregressivo de coeficiente 0,217, a rejeição a 5% chega a 76,6% no painel inteiro e a 89,4% quando a lacuna é vizinha de uma troca; com 50 municípios, varia de 6,8% a 8,2%, e só a célula vizinha de troca ainda é compatível com 5%. Com a máscara real de disponibilidade do índice do estudo, a rejeição é de 34,8%. Sem correlação serial, a lacuna do período 9 dá 6,4%, compatível com 5%. Com a opção `nostitch` que o próprio pacote oferece, a inflação de dezenas de pontos some: 4,6% com 1.000 municípios, 3,6% com a máscara real e de 1,2% a 2,0% no painel inteiro, um teste conservador, embora acima dos 0,2% que o pacote rejeita sem lacuna nenhuma; nas células de 1.000 municípios em que o poder foi medido, sem trechos descartados e sem igualar o tamanho dos testes, ele foi semelhante ao do controle sem lacuna. Com a lacuna no

meio de um mandato longo, o teste ficou conservador, mas o sinal depende da posição da lacuna em relação às fronteiras dos mandatos. A ajuda do pacote recomenda desligar a costura diante de "uma lacuna longa" ou de outra razão que não especifica; os resultados indicam que o comprimento não basta e que a posição da lacuna em relação à troca de líder precisa entrar no diagnóstico. O artigo não afirma que algum resultado publicado de Berry e Fowler esteja errado e não apresenta a correção como nova: ela já existe no pacote. O caso que motivou a investigação, um estudo pré-registrado sobre prefeitos brasileiros, terminou sem evidência de efeito do prefeito e com a conclusão de equivalência não demonstrada.

Palavras-chave: inferência por aleatorização; efeitos de líder; dados faltantes; correlação serial; pré-registro; prefeitos

Abstract

Berry and Fowler's (2021) randomization inference for leader effects (RIFLE) compares how much the true tenures explain an outcome with how much tenures of the same length in shuffled order would explain, and has become the direct way to ask whether a ruler matters "beyond chance". For years without data, the original article and the default of the official Stata package (Berry & Fowler, 2018) drop the missing observations and stitch the remaining blocks into a contiguous time index. This paper shows that, under modest serial correlation, stitching makes the test detect leader effects that do not exist when, in the municipal panel examined, the gap falls next to a mayor transition (the return of the same mayor after the gap can reverse the effect), and that the size of the error grows with the number of units in the panel. The evidence comes from simulations under the null on the real tenure structure of 5,468 Brazilian municipalities (2005-2024), run on a translation of the default path of the official code and registered in a hash chain before each run. With a one-half-term gap right after the election (in 62.3% of the 5,468 municipalities it separates different mayors) and autoregressive noise with coefficient 0.217, rejection at 5% reaches 76.6% in the full panel and 89.4% when the gap borders a transition; with 50 municipalities it ranges from 6.8% to 8.2%, and only the cell next to a transition is still compatible with 5%. With the real availability mask of the study's index, rejection is 34.8%. Without serial correlation, the period-9 gap gives 6.4%, compatible with 5%. With the package's own `nostitch` option, the inflation of tens of points goes away: 4.6% with 1,000 municipalities, 3.6% with the real mask, and 1.2% to 2.0% in the full panel, a conservative test, though above the 0.2% the package rejects with no gap at all; in the 1,000-municipality cells where power was measured, with no blocks dropped and without equalizing test size, it was similar to the no-gap control. With the gap in the middle of a long tenure, the test became conservative, but the sign

depends on the position of the gap relative to tenure boundaries. The package help recommends turning stitching off for “a long gap” or for some other, unspecified reason; the results indicate that length is not enough and that the position of the gap relative to leader transitions must enter the diagnosis. The paper does not claim that any published result by Berry and Fowler is wrong, and does not present the fix as new: it already exists in the package. The case that motivated the investigation, a pre-registered study of Brazilian mayors, ended with no evidence of a mayor effect and with equivalence not demonstrated.

Keywords: randomization inference; leader effects; missing data; serial correlation; preregistration; mayors

1. Introdução

Perguntar se um governante importa é perguntar se o resultado muda com a pessoa, e o RIFLE testa isso comparando a história real com histórias sorteadas. Jones e Olken (2005) mostraram que a morte de chefes de Estado no cargo altera o crescimento, e reacenderam uma linha que procura separar o efeito da pessoa do efeito do contexto. Berry e Fowler (2021) propuseram um procedimento mais direto para a pergunta "além do acaso": regredir o resultado sobre indicadores de líder, guardar o R^2, e compará-lo com a distribuição do R^2 obtida quando a ordem dos mandatos de cada unidade é embaralhada, mantendo a duração de cada um. Se os mandatos verdadeiros explicam mais do que quase todos os sorteios, a hipótese de efeito nulo é rejeitada. Os autores aplicaram o teste a chefes de Estado, governadores e prefeitos dos Estados Unidos, executivos de empresas e técnicos esportivos, e o disponibilizaram como módulo para Stata (Berry & Fowler, 2018). Este artigo mostra que, quando faltam anos no meio da série, a forma padrão de tratar a lacuna pode fazer o teste acusar um líder que não existe.

O procedimento depende de uma escolha que parece de bastidor: o que fazer com os anos sem dado. O artigo original é explícito: "we drop those observations and stitch together blocks of time, coding a new time variable so that we have a single, contiguous stretch of time with complete data for each unit" (Berry & Fowler, 2021) ("descartamos essas observações e costuramos os blocos de tempo, codificando uma nova variável de tempo para ter um único trecho contínuo de dados completos em cada unidade"). O pacote faz o mesmo por padrão e oferece a opção `nostitch`, descrita na ajuda como a que deve ser usada "if there is a long gap between periods or some other reason not to comprate [*sic*] observations across missing periods" (Berry & Fowler, 2018) ("se há uma lacuna longa entre períodos ou outra razão para não comparar observações através de períodos faltantes"). Nenhuma das simulações de tamanho dos

autores combina lacuna e correlação serial: as de 20 unidades por 20 períodos, com peso 0 ou 0,2 no período anterior, não têm lacunas; as de troca endógena de líder, com o número de unidades e de períodos de cada aplicação, encadeiam o resultado simulado na ordem das linhas, ordenadas pelo calendário mas aplicando a correlação à linha anterior mesmo quando o ano salta, segundo o código de replicação (Berry & Fowler, 2020), e por isso não produzem o descompasso entre calendário e tempo costurado de que trata este artigo; as de poder, que com efeito zero medem cerca de 5% de rejeição, usam ruído independente; e as do material suplementar tratam de custo de transição em painéis completos, sem correlação serial.

Este artigo nasceu de um estudo pré-registrado que aplicou o RIFLE a prefeitos brasileiros, com um índice de nota escolar, receita própria e mortalidade infantil, de 2005 a 2024. Na fase piloto, antes de qualquer conta com prefeitos verdadeiros, o teste com a costura rejeitou o nulo verdadeiro em 64,0% de 200 simulações nos municípios com lacuna interior, quando o certo seria 5% (Seção 5.6). O estudo parou e foi refeito, e a pergunta passou a ser outra: o que, na lacuna, engana o teste?

A resposta tem quatro partes, todas medidas numa tradução fiel do código oficial:

1. **No painel municipal examinado, a costura padrão rejeita demais quando a lacuna cai junto de uma troca de prefeito** e o resultado tem correlação serial positiva (Seção 5.1); quando o mesmo prefeito volta depois da lacuna, o sinal pode se inverter (Seção 3.2).
2. **O comprimento da lacuna não basta para avaliar o risco.** Uma lacuna curta, de um único período por município, já pode distorcer sob correlação serial, e o sinal da distorção

depende de onde a lacuna cai em relação às fronteiras dos mandatos; na célula testada, a lacuna no meio de um mandato longo deixou o teste conservador (Seções 3.2, 3.3 e 5.1).

3. **O erro aumenta fortemente nos painéis maiores examinados**: com 50 municípios varia de 6,8% a 8,2% (só a célula vizinha de troca ainda é compatível com 5%) e chega a 89,4% com 5.468 (Seção 5.2).

4. **A opção `nostitch`, que já existe no pacote, tira a inflação de dezenas de pontos** nos casos testados; no painel inteiro, o teste fica conservador, e o poder, medido só com 1.000 municípios, foi semelhante ao do controle sem lacuna (Seções 5.1 a 5.3).

A ajuda do pacote já traz a opção que restringe o sorteio a trechos contínuos; as partes 1 a 3 e a medida da parte 4 não estão no artigo original, no seu material suplementar, no código de replicação dos autores nem na ajuda, e não foram localizadas nas demais fontes examinadas (Seção 6.3). O artigo não reivindica a correção, que é dos autores; reivindica a medida do problema, os exemplos de mudança de sinal e um diagnóstico para decidir quando usá-la. Também não afirma que algum resultado publicado de Berry e Fowler esteja errado (Seção 6.2).

2. Trabalhos relacionados

A pergunta sobre líderes já foi feita muitas vezes; nas fontes examinadas, não localizamos uma medida do tamanho do teste quando falta dado no meio da série. A decomposição de variância por líder tem uma história de controvérsia sobre o quanto o "efeito do executivo" excede o acaso. O desenho de Jones e Olken identifica o efeito por poucas trocas inesperadas, 57 num painel de 130 países desde 1945 segundo Berry e Fowler (2021), e o RIFLE usa todas as trocas. Fitza (2014) mostrou que boa parte da variância atribuída a presidentes de empresa podia ser reproduzida por sorte; Quigley e Graffin (2017) responderam que o efeito é significativo e

maior do que o acaso. O RIFLE (Berry & Fowler, 2021) transformou essa discussão num teste de permutação com regra de decisão clara, e Smith e Gray (2021) o estenderam a séries históricas longas e o revalidaram em dados simulados. Dos 42 registros que citam Berry e Fowler no OpenAlex (31 de outubro de 2026; alguns são versões de um mesmo trabalho), nenhum título menciona lacunas nem o tamanho do teste; a triagem é fraca e não recuperou Smith e Gray. Este artigo só leu o resumo dessa extensão, que não menciona lacunas; como séries históricas costumam ter anos faltando, o texto completo pode tratar do problema (ver Seção 6.3).

A validade de um teste de permutação vem da simetria dos dados sob o nulo, não do nulo em si. Lehmann e Romano (2005) apresentam o resultado clássico: o teste é exato quando a distribuição conjunta dos dados é invariante sob o grupo de permutações usado. Winkler et al. (2014) discutem o que acontece quando essa intercambiabilidade só vale em blocos e por que restrições ao sorteio podem ser necessárias. Canay, Romano e Shaikh (2017) tratam de testes de aleatorização sob simetria apenas aproximada. A lição comum é que "efeito de líder zero" não implica, sozinho, que todas as ordens de mandato sejam igualmente prováveis; isso depende da estrutura de dependência do resultado, e é exatamente essa estrutura que a costura altera.

Reamostrar dados dependentes exige preservar a dependência que importa. A literatura de bootstrap em blocos (Künsch, 1989; Politis & Romano, 1994; Lahiri, 2003) mostra que blocos contíguos preservam a dependência local de séries estacionárias e que as junções entre blocos são justamente onde essa dependência deixa de ser reproduzida; o bootstrap estacionário emenda blocos de propósito e continua consistente, porque trata as junções como parte do desenho. O RIFLE não é um bootstrap e as justificativas são diferentes, mas o princípio transfere: reordenar blocos num índice de tempo que não corresponde ao calendário compara partições sob covariâncias que não são as que os dados têm.

No Brasil, a pergunta sobre prefeitos foi feita com outros desenhos. Akhtari, Moreira e Trucco (2022) mostraram, com eleições apertadas, que a troca de partido no comando do município troca diretores e professores e reduz a nota dos alunos; Brollo e Nannicini (2012) mostraram que prefeitos alinhados ao presidente recebem mais transferências discricionárias para infraestrutura em anos pré-eleitorais, razão pela qual o estudo pré-registrado retirou do resultado o efeito do alinhamento partidário. Pelo levantamento feito para este artigo (Seção 6.3), o RIFLE não havia sido aplicado a prefeitos brasileiros, com a confiança média declarada ali. O estudo seguiu a lógica de pré-registro defendida por Nosek et al. (2018): regras de decisão gravadas antes dos dados, emendas datadas e nada descartado depois de ver o resultado.

3. O procedimento, a costura e o mecanismo

3.1 O RIFLE e o que a costura faz

O teste compara uma partição real com partições sorteadas, e a costura muda quais partições são possíveis. Para cada unidade m com períodos $t = 1, \ldots, T$, o resultado y é residualizado por efeitos de período. O R^2 real vem da regressão sobre indicadores de líder; cada permutação sorteia a ordem dos mandatos da unidade, mantendo a duração, e recalcula o R^2. O valor-p é a fração de permutações com R^2 maior que o real. No código oficial (`rifle.ado`, Berry & Fowler, 2018), três detalhes importam aqui:

- o resultado é residualizado por período antes de descartar faltantes, o que, para resultado faltante, equivale a descontar a média do período nas células observadas;
- os indicadores são da **identidade** do líder (`absorb(leader)`), de modo que a mesma pessoa em dois mandatos separados forma um único grupo;

- o mandato (“stint”) muda quando muda o líder, na ordem do tempo renumerado, de modo que a mesma pessoa dos dois lados de uma lacuna costurada vira um mandato só.

Com a costura, o período depois da lacuna passa a ser vizinho, no índice de tempo, do período antes dela. Com `nostitch`, cada trecho contínuo de períodos observados vira uma unidade própria de sorteio, e o trecho com um só líder e duas ou mais linhas sai da amostra.

3.2 Dois líderes bastam para ver o mecanismo

A covariância entre dois períodos continua sendo a do calendário, não a do índice costurado. Seja o resultado, sob o nulo, um processo autorregressivo estacionário com variância σ^2 e covariância $\sigma^2\rho^{|t-s|}$ entre os períodos t e s do calendário, com $0 < \rho < 1$. Para uma partição G em grupos g de tamanho n_g, a soma de quadrados explicada é, a menos de um termo comum a todas as partições,

$$Q = \sum_{g} \frac{1}{n_g} \left(\sum_{t \in g} y_t \right)^2 , \tag{1}$$

e o denominador do R^2 é o mesmo em todas as permutações de uma mesma base. Ordenar R^2 equivale, então, a ordenar Q, cuja esperança é

$$\mathrm{E}[Q] = \sum_{g} \frac{1}{n_g} \sum_{t,s \in g} \sigma^2 \, \rho^{|t-s|}. \tag{2}$$

Considere seis períodos com o líder A em 1-2 e B em 3-6, e a única reordenação possível, B antes de A.

- **Lacuna vizinha da troca** (falta o período 3): a partição real é {1, 2} | {4, 5, 6}; a invertida, na sequência costurada, é {1, 2, 4} | {5, 6}. A partição invertida põe a lacuna

dentro de um grupo, onde ela reduz a covariância interna. Com Q_{inv} o valor da ordem invertida, resulta

$$\mathrm{E}[Q_{\text{real}} - Q_{\text{inv}}] = \frac{2}{3}\sigma^2(\rho - \rho^3) > 0, \tag{3}$$

e o ajuste real fica favorecido sem nenhum efeito de líder.

- **Lacuna dentro do mandato** (falta o período 4): a partição real é {1, 2} | {3, 5, 6}, e a invertida, {1, 2, 3} | {5, 6}. Os papéis se trocam:

$$\mathrm{E}[Q_{\text{real}} - Q_{\text{inv}}] = -\frac{2}{3}\sigma^2(\rho - \rho^3) < 0, \tag{4}$$

e a diferença média vai no sentido conservador, a favor do sorteio.

- **Lacuna dentro do mandato que ainda infla** (contraexemplo da revisão externa): com A em 1-4, B em 5-6 e o período 2 faltando, a partição real é {1, 3, 4} | {5, 6} e a invertida, {1, 3} | {4, 5, 6}. Então

$$\mathrm{E}[Q_{\text{real}} - Q_{\text{inv}}] = \frac{1}{3}\sigma^2\rho(1 - \rho)(1 - 2\rho), \tag{5}$$

positivo para $\rho < 0{,}5$ (cerca de $0{,}032\sigma^2$ com $\rho = 0{,}217$). A lacuna está dentro do mandato de A, e o ajuste real fica favorecido.

- **Lacuna vizinha da troca com diferença média negativa** (segundo contraexemplo da revisão externa): com A em 1-2, B em 3-4, A de volta em 5-6 e o período 3 faltando, o pacote sorteia três passagens e reúne as duas de A num só grupo; a média sobre as seis ordens dá

$$\mathrm{E}[Q_{\mathrm{real}} - Q_{\mathrm{perm}}] = -\frac{1}{6}\sigma^2\rho^2(1-\rho)(2\rho^2+4\rho+3), \tag{6}$$

cerca de $-0{,}024\sigma^2$ com $\rho = 0{,}217$. Nesse caso o retorno de A já desloca a estatística no sentido conservador mesmo sem lacuna nenhuma (cerca de $-0{,}102\sigma^2$ com os seis períodos completos, pela mesma enumeração), porque as duas passagens de A nunca são vizinhas nos dados reais e passam a sê-lo em quatro das seis ordens; a lacuna reduz esse deslocamento, mas não o inverte. É a mesma candidata a causa do conservadorismo do pacote sem lacuna (Seção 5.1).

Os exemplos usam a covariância do calendário antes do desconto da média do período, que o teste faz; com máscaras diferentes entre municípios, esse desconto muda a matriz de covariância e liga as unidades, de modo que a passagem dos exemplos para o painel é um argumento heurístico, e as simulações aplicam o desconto exatamente. Com $\rho = 0$ os quatro contrastes desaparecem. O sinal depende, portanto, de como a lacuna se posiciona em relação às fronteiras dos grupos reais e dos sorteados, inclusive dos grupos que juntam um líder que volta, e não só de ela estar junto de uma troca ou dentro de um mandato. Esses sinais são de diferenças médias, não de taxas de rejeição: num painel de dois municípios com a estrutura do segundo exemplo, a diferença média é negativa e, ainda assim, o teste rejeita em 48,1% de 4.000 bases (a ordem real tem R^2 maior que a invertida em 47,3% de 400 mil bases, com ruído gaussiano e o desconto da média do período), porque os resíduos dos dois municípios são opostos, as três ordens que não são a real ficam do mesmo lado dela, e o valor-p exato, contando só as ordens estritamente maiores, é 0 ou 0,75; com 200 sorteios, a estimativa oscila em torno desses dois polos. Essa patologia de painéis minúsculos com cauda estrita existe mesmo sem lacuna e sem correlação

serial, e não é o mecanismo da costura. A derivação foi proposta pela revisão externa deste trabalho (Seção 4.4); as taxas de rejeição foram medidas por simulação.

3.3 Por que o painel grande amplifica e o comprimento não decide

O deslocamento por unidade é pequeno, mas soma; a dispersão do teste cresce mais devagar. Se o deslocamento médio por município na diferença entre a soma de quadrados explicada real e a permutada tem sinal definido no conjunto do painel, positivo quando predominam lacunas vizinhas de troca sem retorno de líder, a soma sobre N unidades independentes cresce com N, enquanto a sua dispersão sob o nulo cresce aproximadamente com $\sqrt{N}$. No R^2, que divide as duas somas pela soma de quadrados total, também proporcional a N, o deslocamento fica de ordem constante e a dispersão cai com $1/\sqrt{N}$; a razão entre os dois cresce com $\sqrt{N}$ nos dois casos. Por isso o mesmo viés por unidade é quase invisível em 50 unidades e decisivo em milhares; nas simulações, cada tamanho usa outra subamostra, e o crescimento concorda com o mecanismo sem isolá-lo. O comprimento da lacuna entra na covariância perdida (o par emendado passa de ρ para ρ^{L+1}), mas não decide o sinal: a mesma lacuna curta desloca a estatística a favor do ajuste real quando separa dois líderes diferentes que não voltam, pode deslocá-la para qualquer lado quando fica dentro de um mandato e, nos casos de retorno calculados aqui, a desloca no sentido conservador, conforme as fronteiras da Seção 3.2.

4. Dados e desenho das simulações

4.1 A tradução do código oficial e o seu limite

Os números de capa vêm de uma tradução do caminho padrão do `rifle.ado` distribuído no SSC (a versão com as opções `controls` e `notrend`; a cópia `RIFLE.do` do código de

replicação não as tem, mas costura e `nostitch` são idênticos) para Python, porque não havia Stata disponível; esse é o principal limite do artigo. A tradução cobre o R^2 sem controles, a costura e o `nostitch`; não implementa as opções `controls`, `growth` e `notrend`, e supõe que só o resultado tem faltantes (unidade, líder e período sempre presentes, como nas simulações). Ela reproduz os passos citados na Seção 3.1, com a linha correspondente do código anotada (`code/rifle_ado.py` no pacote de replicação; Flores, 2026). Ela foi conferida contra contas feitas à mão em painéis pequenos (três testes que cobrem costura, fusão da mesma pessoa e regras do `nostitch`), contra a enumeração exata das 36 ordens de passagens num painel de duas unidades com um líder que volta (o valor-p do sorteio dá 0,1103 com 200 mil permutações, contra 0,1111 exato), contra a mesma enumeração num painel com `nostitch`, trecho descartado, trecho de uma linha e a mesma pessoa nos dois trechos (0,7511 contra 0,75 exato), contra uma reconstrução independente da média que inclui a linha real (igual até a 12ª casa e diferente da média sem ela) e contra o motor próprio do estudo num painel sem retorno de prefeito, onde os dois coincidem no valor registrado na cadeia (R^2 de 0,4777757). Isso não substitui um confronto com o Stata, que o pacote de replicação deixa preparado no arquivo `stata/rifle_celulas.do` para quem o tiver (Seção 7).

4.2 A estrutura de mandatos

A estrutura é real; o resultado é sintético. Os prefeitos de cada meio-mandato (dez períodos de dois anos, 2005-2024) foram identificados a partir dos dados abertos do Tribunal Superior Eleitoral, incluindo eleições suplementares, com a pessoa identificada pelo CPF validado (TSE, 2024). Nas simulações, a identidade do líder é o par município-pessoa: quem foi prefeito em dois municípios conta como dois líderes, o que evita que o agrupamento global do pacote junte cidades diferentes. Entram 5.468 municípios com prefeito identificado nos dez períodos e ao

menos dois prefeitos diferentes. Nenhum resultado real entra nas simulações, com duas exceções: o coeficiente do gerador, calibrado a partir de uma estatística do índice real (Seção 4.3), e, na Seção 5.3, a informação de **quais** municípios-período têm o índice observado.

4.3 O gerador e as células

O ruído é autorregressivo de ordem um no calendário, com coeficiente 0,217, e a lacuna é imposta depois de gerado o ruído. O ruído é gaussiano, estacionário desde o primeiro período (variância 1 e inovações de variância $1 - \rho^2$) e independente entre municípios; nas células de poder, cada pessoa recebe um efeito gaussiano de variância Prop/(1 − Prop), o mesmo nos dois lados de uma lacuna. O coeficiente é o do gerador calibrado no estudo pré-registrado: a autocorrelação medida no índice real depois de descontar município e período foi 0,084, valor viesado para baixo pelo desconto da média em séries curtas (Nickell, 1981), e 0,217 é o coeficiente autorregressivo cuja autocorrelação, medida com o mesmo desconto em séries sintéticas de dez períodos, reproduz os 0,084 (método dos momentos, por bisseção). Cada célula tem 500 bases e 1.000 permutações por base; as taxas de rejeição a 5% vêm com intervalos exatos de 95% (Clopper & Pearson, 1934). Em cada célula, a subamostra de municípios e a posição das lacunas são sorteadas uma vez e ficam fixas nas 500 bases; os intervalos medem a incerteza de Monte Carlo dentro desse desenho, não a variação entre subamostras ou máscaras. As células variam:

- a posição da lacuna: nenhuma; o período 9 (primeiro meio-mandato depois da eleição de 2020, o mesmo que falta no Saeb de 2021); um período interior sorteado; um período vizinho de troca; um período dentro de um mandato;
- o tratamento: costura padrão ou `nostitch`;

- o número de municípios: subamostras aleatórias de 50, 200 e 1.000 e o painel inteiro;
- o coeficiente: 0,217 ou 0;
- a presença de efeito: sem efeito, ou efeito por pessoa com 10% ou 5% da variância, para medir poder.

As células condicionadas à posição da lacuna só aceitam municípios em que essa posição existe, e por isso têm menos municípios que a subamostra de 1.000; a Tabela 1 traz o número efetivo de cada uma. Os controles da mesma amostra (sem lacuna, nos mesmos 867 municípios) e as células do `nostitch` no painel inteiro foram acrescentados depois da revisão externa do texto: o módulo entrou na cadeia de hash antes da sua saída, e a regra de leitura foi escrita no pré-registro do artigo antes de rodar, mas fora de qualquer cadeia (Seção 4.4).

Tabela 1

Células do pacote fiel: desenho e rejeição a 5% (500 bases, 1.000 permutações cada)

Módulo	Municípios	Observações usadas	Lacuna	Tratamento	ρ	Efeito (Prop)	Rejeição (%)	IC 95% exato (%)
diagnostico_ado	1.000	10.000	nenhuma	costura	0,217	0%	2,2	1,10 a 3,90
diagnostico_ado	1.000	9.000	período 9	costura	0,217	0%	27,2	23,34 a 31,33
diagnostico_ado	867	7.803	meio de mandato	costura	0,217	0%	0,2	0,01 a 1,11
diagnostico_ado	1.000	9.000	período 9	costura	0,000	0%	6,4	4,42 a 8,92
diagnostico_ado	1.000	9.000	período 9	nostitch	0,217	0%	4,6	2,94 a 6,82
diagnostico_ado	869	7.821	sorteada, 2+ prefeitos em cada trecho	nostitch	0,217	0%	6,2	4,25 a 8,69
diagnostico_ado	1.000	10.000	nenhuma	costura	0,217	10%	98,8	97,41 a 99,56
diagnostico_ado	867	7.803	meio de mandato	costura	0,217	10%	96,8	94,86 a 98,16
diagnostico_ado_juizes	867	8.670	nenhuma	costura	0,217	0%	2,2	1,10 a 3,90
diagnostico_ado_juizes	867	8.670	nenhuma	costura	0,217	10%	99,0	97,68 a 99,67
diagnostico_ado_juizes	1.000	9.000	período 9	nostitch	0,217	10%	98,4	96,87 a 99,31
diagnostico_ado_juizes	869	7.821	sorteada, 2+ prefeitos em cada trecho	nostitch	0,217	10%	99,0	97,68 a 99,67
diagnostico_ado_juizes	1.000	10.000	nenhuma	costura	0,217	5%	55,0	50,52 a 59,42
diagnostico_ado_juizes	1.000	9.000	período 9	nostitch	0,217	5%	61,0	56,57 a 65,30
diagnostico_ado_escala	5.468	—	período 9	costura	0,217	0%	76,6	72,64 a 80,24
diagnostico_ado_escala	5.468	—	vizinha de troca	costura	0,217	0%	89,4	86,36 a 91,96
diagnostico_ado_escala	5.468	—	interior sorteada	costura	0,217	0%	34,6	30,43 a 38,95
diagnostico_ado_juizes	5.468	54.680	nenhuma	costura	0,217	0%	0,2	0,01 a 1,11
diagnostico_ado_juizes	5.468	49.212	período 9	nostitch	0,217	0%	1,6	0,69 a 3,13
diagnostico_ado_juizes	5.468	40.533	vizinha de troca	nostitch	0,217	0%	1,2	0,44 a 2,59
diagnostico_ado_juizes	5.468	42.972	interior sorteada	nostitch	0,217	0%	2,0	0,96 a 3,65
diagnostico_ado_mascara_real	1.854	—	máscara real do índice, municípios com lacuna interior	costura	0,217	0%	34,8	30,63 a 39,16
diagnostico_ado_mascara_real	1.854	—	máscara real do índice, municípios com lacuna interior	nostitch	0,217	0%	3,6	2,15 a 5,63
diagnostico_ado_mascara_real	707	—	máscara real do índice, só lacuna de borda	costura	0,217	0%	3,8	2,30 a 5,87

Fonte: `results.json` do estudo (saídas com sha256 conferido). Município sem lacuna: 10 observações. As linhas da máscara real usam só a informação de quais municípios-período têm o índice; o resultado é sintético. Efeito = fração da variância devida ao prefeito; 0% = nulo verdadeiro. Observações usadas = municípios-período que entram no teste depois da lacuna e, no `nostitch`, do descarte de trechos com um só prefeito; não registrado (—) nas células de escala e da máscara real. Nas células com lacuna no período 9 e `nostitch`, as observações usadas incluem o período 10, trecho de uma linha que nunca é sorteado e que não contribui para a variação entre permutações quando o seu prefeito não aparece no outro trecho. Municípios = unidades que entram na célula antes do descarte de trechos pelo `nostitch`.

4.4 Registro e revisão

Cada experimento foi gravado numa cadeia de hash antes de rodar, e a tese e o texto passaram por revisores independentes. Os módulos, as sementes e as regras de passar ou parar dos experimentos principais foram registrados com SHA-256 antes de cada execução (as regras de leitura das células acrescentadas na revisão ficaram fora da cadeia, Seção 4.3), em cadeias encadeadas (`manifest.jsonl`) que o pacote de replicação publica (Flores, 2026); o encadeamento garante a integridade e a ordem dos registros, mas os carimbos de tempo vêm da data de modificação dos arquivos, sem carimbo externo, e por isso a anterioridade é declarada, não autenticada. Os testes de fumaça usaram sementes descartáveis declaradas no próprio registro. A tese foi revisada por um conselho de modelos de linguagem (um deles encontrou a opção `nostitch` na ajuda do pacote, que a busca anterior não tinha lido) e o texto, por três modelos de linguagem de famílias diferentes, com a mesma instrução e sem ver o parecer um do outro. Cada crítica recebeu resposta registrada.

5. Resultados

5.1 Onde a lacuna cai decide

Na subamostra de mil municípios, a mesma lacuna curta leva o teste de 0,2% (867 municípios) a 27,2% de rejeição conforme a posição, contra 2,2% sem lacuna. A Figura 1 resume as células da subamostra de 1.000 municípios, com o número efetivo de cada barra. Sem lacuna, o pacote rejeita 2,2% (intervalo de 1,10% a 3,90%), um conservadorismo leve do próprio pacote cuja causa não foi isolada: o valor-p estrito não o explicaria, e a candidata é o retorno de prefeitos ao cargo (Seção 3.2). Com a lacuna do período 9 costurada, a rejeição sobe para 27,2% (de 23,34% a 31,33%). Com a lacuna dentro de um mandato, nos 867 municípios que têm um

prefeito por três períodos seguidos, cai para 0,2%, contra 2,2% sem lacuna nesses mesmos municípios.

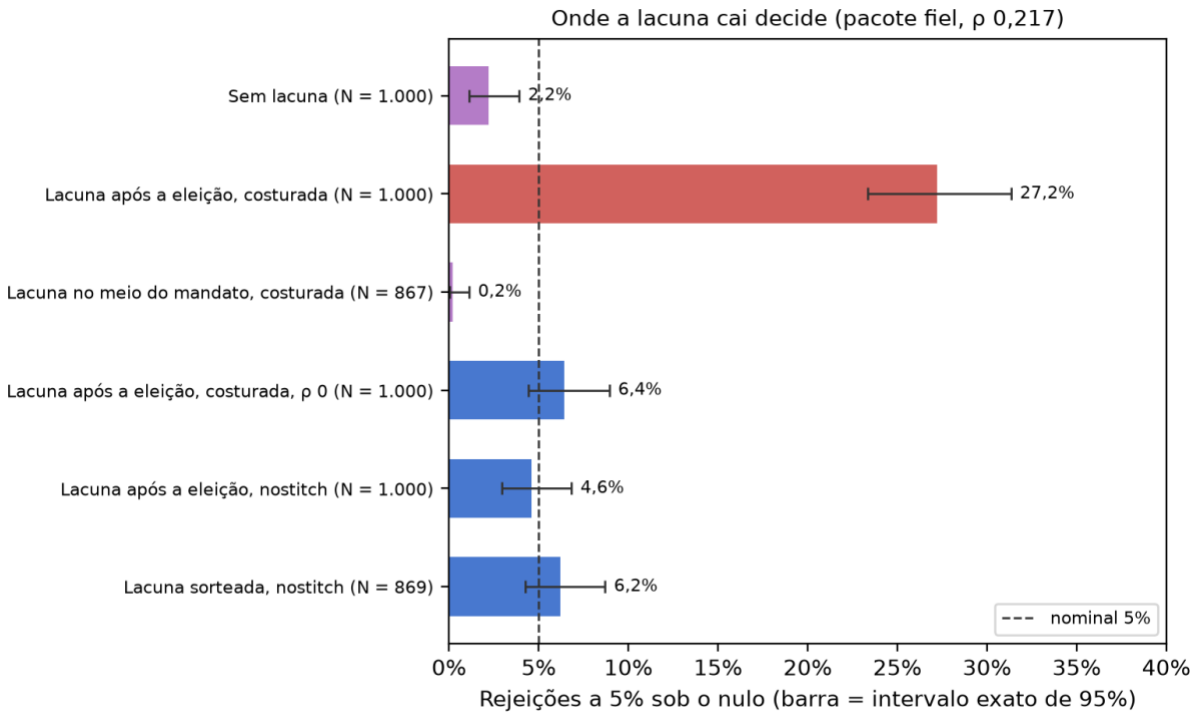
O conservadorismo da lacuna dentro do mandato não apaga o poder. Com efeito por pessoa de 10% da variância, nos mesmos 867 municípios, o teste detecta o efeito em 96,8% das bases com lacuna dentro do mandato, contra 99,0% sem lacuna. O desvio no sentido conservador pesa sob o nulo e quase não pesa diante de um efeito desse tamanho.

Sem correlação serial, desaparece o contraste de covariâncias da Seção 3.2. Com $\rho = 0$ e a lacuna do período 9, a rejeição é de 6,4%, compatível com 5% na precisão de 500 bases.

A opção que o pacote já oferece tira a inflação de dezenas de pontos nos casos testados. Com `nostitch`, a lacuna do período 9 dá 4,6%, e uma lacuna interior sorteada, com dois ou mais prefeitos nos dois trechos, dá 6,2% (de 4,25% a 8,69%); as duas são compatíveis com 5% na precisão de 500 bases, e o intervalo da segunda não exclui uma inflação de alguns pontos. A segunda célula reduz, sem excluir, a suspeita de que o `nostitch` só funcione por deixar trechos sem sorteio útil. Com efeito de prefeito, o `nostitch` detecta 98,4% com 10% da variância, contra 98,8% sem lacuna, e 61,0% com 5%, contra 55,0% sem lacuna; com a lacuna sorteada de dois ou mais prefeitos por trecho e 10% da variância, 99,0%. Essas comparações têm dois limites: nessas células o `nostitch` não descarta nenhum trecho, e o controle sem lacuna já rejeita menos sob o nulo (2,2% contra 4,6%). O poder nas posições em que o `nostitch` descarta trechos, como a lacuna vizinha de troca (no painel inteiro, o `nostitch` descarta 17,6% das células que restam depois da lacuna), e no painel de 5.468 municípios não foi medido.

Figura 1

Rejeição sob o nulo na subamostra de 1.000 municípios (N efetivo em cada barra), conforme a posição da lacuna e o tratamento (tradução fiel do pacote; barras: intervalo exato de 95%)



5.2 O painel grande transforma um viés pequeno em erro sistemático

De 50 para 5.468 municípios, a rejeição com a lacuna vizinha de troca vai de 6,8% a 89,4%. A Figura 2 mostra as três posições de lacuna sob a costura padrão. Com a lacuna vizinha de troca, a rejeição é de 6,8% com 50 municípios (de 4,75% a 9,37%, ainda compatível com 5%), 14,2% com 200, 35,2% com 1.000 e 89,4% com o painel inteiro. Com a lacuna do período 9, os valores são 8,2%, 15,8%, 26,2% e 76,6%. Com uma lacuna interior sorteada, de 7,8%, 7,6%, 14,4% e 34,6%.

Uma lacuna de um só período, sorteada, já distorce. A ajuda do pacote diz que a costura é vantajosa quando "a few years are missing idiosyncartically" [*sic*] ("faltam poucos anos de

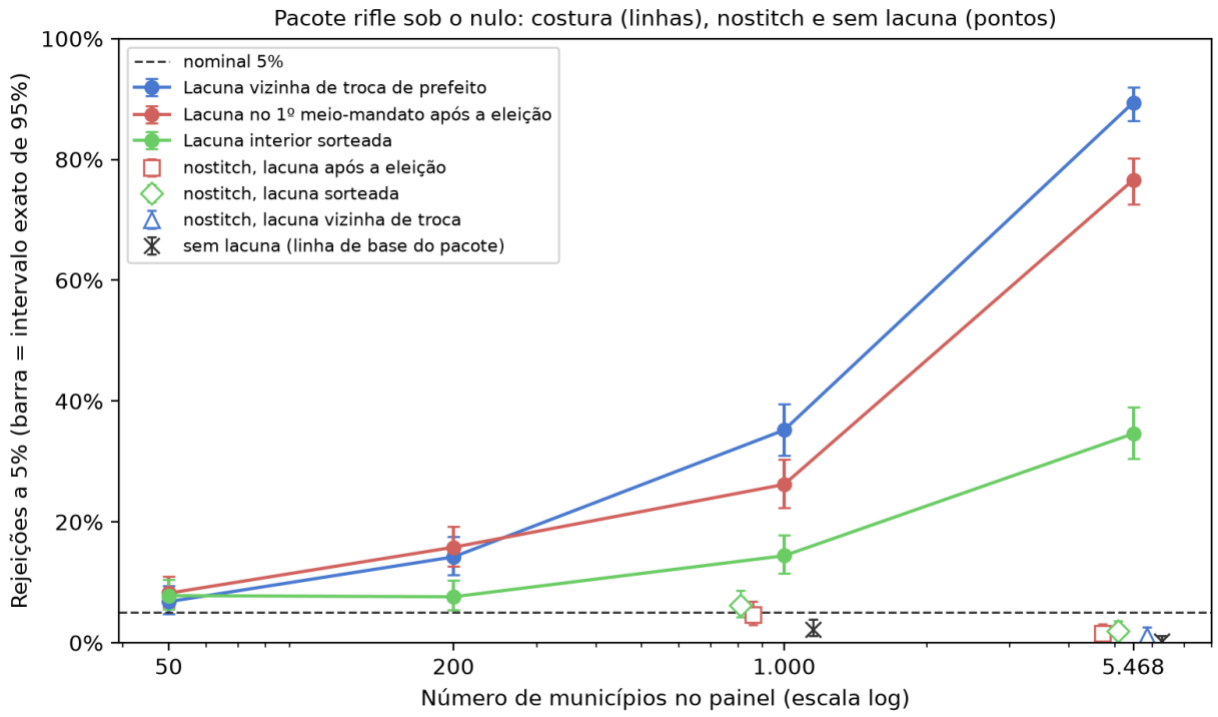
forma idiossincrática"). Nos mandatos municipais brasileiros, 70,1% das lacunas sorteadas caem vizinhas de uma troca de prefeito, e a rejeição no painel inteiro chega a 34,6%. O caso em que a ajuda vê vantagem na costura não é seguro quando os mandatos são curtos e o painel é grande. A fração de lacunas vizinhas de troca é um diagnóstico útil, mas não uma regra suficiente: a magnitude depende também da autocorrelação, da duração dos mandatos, do retorno de líderes e do número de unidades.

Os 26,2% com 1.000 municípios e lacuna no período 9 vêm de subamostra e semente diferentes das dos 27,2% da Seção 5.1. A célula do período 9 é uma mistura: em 62,3% dos municípios a lacuna separa prefeitos diferentes e, nos demais, a mesma pessoa está dos dois lados; o caso puro de lacuna entre prefeitos diferentes é a célula vizinha de troca, com 89,4%.

No painel inteiro, o `nostitch` tira a inflação de dezenas de pontos e deixa um teste conservador. Sem lacuna nenhuma, o pacote rejeita 0,2% com os 5.468 municípios, contra 2,2% na subamostra de 1.000; como o número de unidades e a composição mudam juntos, e a causa do conservadorismo não foi isolada, a comparação só mostra que ele é maior no painel inteiro. Com `nostitch`, as três posições de lacuna dão 1,6% (período 9), 1,2% (vizinha de troca) e 2,0% (sorteada), contra 76,6%, 89,4% e 34,6% com a costura. Nenhum dos três intervalos contém 5%, e as três estimativas ficam acima da linha de base sem lacuna, como as de 1.000 municípios (4,6% e 6,2% contra 2,2%). Os dados não separam o que vem do conservadorismo do pacote e o que vem das ligações entre trechos da Seção 6.1.

Figura 2

Costura padrão do pacote (linhas): rejeição sob o nulo por número de municípios e posição da lacuna; pontos: `nostitch` *e linha de base sem lacuna, com 1.000 municípios (a lacuna sorteada com* `nostitch` *usa 869 municípios com dois ou mais prefeitos em cada trecho) e no painel inteiro (tradução fiel do pacote; eixo horizontal em escala logarítmica, com os pontos levemente deslocados para não se sobreporem; barras: intervalo exato de 95%)*



5.3 As lacunas reais repetem o padrão

Com as lacunas que o índice real tem, a costura rejeita 34,8% e o `nostitch`, 3,6%. Usando só a informação de quais municípios-período têm índice observado no estudo pré-registrado, e resultado sintético, os 1.854 municípios com lacuna interior rejeitam 34,8% sob a costura (de 30,63% a 39,16%) e 3,6% com `nostitch`. Os 707 municípios com lacuna só no começo ou no fim da série rejeitam 3,8% sob a costura: lacuna de borda não emenda nada e não distorce.

5.4 O motor do estudo dava números maiores

O motor próprio do estudo, que rotula cada passagem de um prefeito como um grupo, deu rejeições maiores; o agrupamento é uma explicação possível, não isolada. Nesse motor, as mesmas células dão números maiores: 98,2% com a lacuna do período 9 no painel inteiro, 76,0% com a lacuna sorteada e 71,4% com uma lacuna de dois períodos. A fusão da mesma pessoa dos dois lados de uma lacuna costurada acontece nos dois códigos; só o pacote junta num mesmo grupo quem volta ao cargo depois de outro prefeito, mas os códigos também diferem na comparação do valor-p (maior ou igual no motor, estritamente maior no pacote) e nas sementes. A célula de dois períodos, que apaga um mandato inteiro, não é usada como evidência sobre o comprimento. Os números de capa deste artigo vêm do pacote; os do motor ficam como sensibilidade.

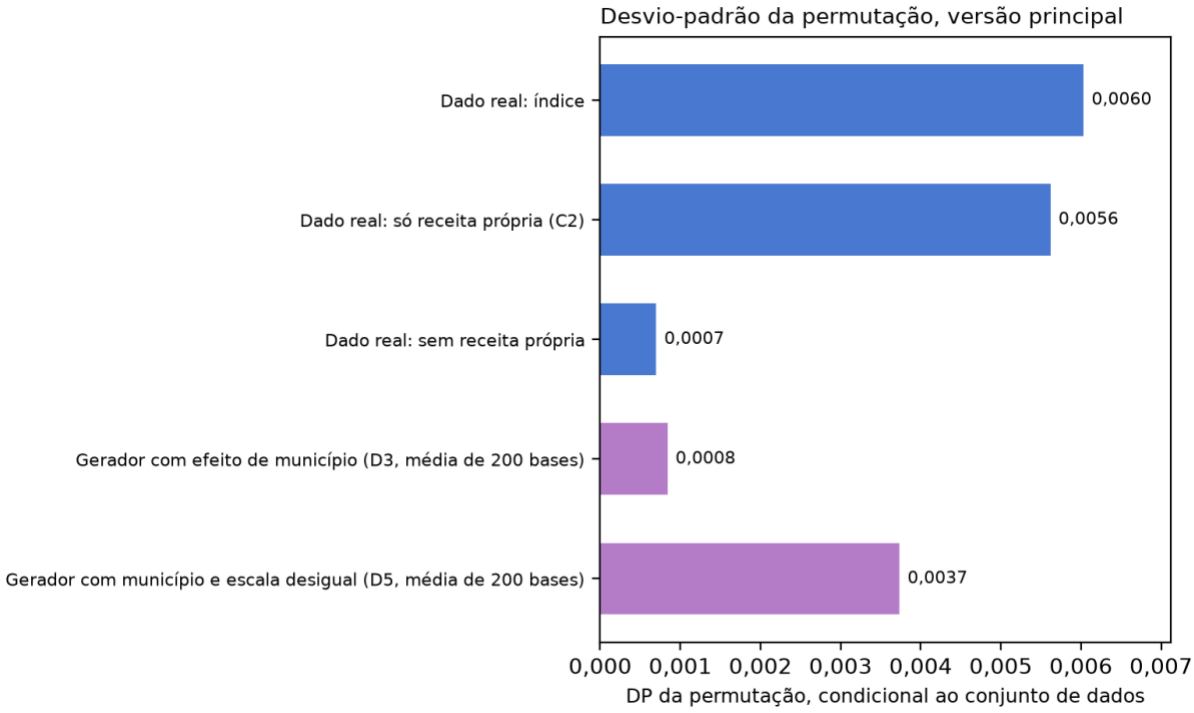
5.5 O caso que motivou a investigação

O estudo pré-registrado terminou sem evidência de efeito do prefeito, e sem poder afirmar que o prefeito não importa. Refeito com sorteio dentro de trechos contínuos (análogo ao `nostitch`, mas com cada passagem do prefeito como grupo próprio), com tamanho confirmado em 5,2% numa rodada pré-declarada de 2.000 bases, o teste foi aplicado uma única vez aos dados reais. O R^2 dos prefeitos verdadeiros ficou abaixo da média dos sorteios nas três versões pré-registradas, com valor-p de 0,869 na amostra principal, 0,488 com efeito defasado e 0,904 nos municípios com 20 mil habitantes ou mais. A regra pré-registrada de equivalência produziu "não importa", mas uma auditoria posterior ao resultado mostrou que o limiar dessa regra fora calibrado sem diferenças entre municípios, e o registro final do estudo é: equivalência não demonstrada, conclusão inconclusiva quanto à exclusão de efeitos relevantes.

A mesma auditoria achou que pouquíssimas séries de receita própria dominam a distribuição do teste, e parte delas era erro de declaração. O desvio-padrão da distribuição de permutação no dado real é quase todo da receita própria (Figura 3; contribuições calculadas mantendo fixo o denominador do índice completo): 0,0056 só com ela, contra 0,0007 sem ela, num total de 0,0060. Entre as células mais extremas estavam totais negativos de receita própria em 2024, valor impossível: 34 municípios, 31 deles no Tocantins, com IPTU declarado com sinal negativo na Declaração de Contas Anuais (Tesouro Nacional, 2025), com mediana de cerca de 19,6 milhões de reais negativos por município. Tratar esses valores como ausentes, por regra gravada antes de rodar de novo, não mudou o resultado da amostra principal, cujo valor-p ficou em 0,862. Mudou numa sensibilidade exploratória, a que inclui passagens de um único período: o valor-p caiu de 0,129 para 0,028, abaixo de 5%. A regra pré-registrada de decisão olha a amostra principal; essa sensibilidade não altera a decisão confirmatória e fica relatada como sinal exploratório, que pede investigação própria.

Figura 3

Largura da distribuição de permutação na amostra principal do estudo: dado real com e sem a receita própria, contra dois geradores sintéticos (mesma grandeza: desvio-padrão condicional ao conjunto de dados; as barras do dado real com e sem a receita própria mantêm fixo o denominador do índice completo)



5.6 A primeira medida, no desenho pré-registrado

O número que parou o estudo, 64%, é o tamanho do teste pré-registrado do projeto, não o do pacote. Na fase piloto, com o motor do estudo, a costura nos municípios com lacuna interior rejeitou 64,0% (de 56,93% a 70,65%) e nos municípios com lacuna só de borda, 5,0%. Essa diferença entre borda e interior foi a primeira evidência de que o problema estava na emenda. Com o pacote, o mesmo conjunto de lacunas dá 34,8% (Seção 5.3). As duas medidas são corretas, cada uma para o seu procedimento.

6. Discussão

6.1 O que muda para quem usa o teste

Em painéis com muitas unidades e lacunas no meio da série, a costura padrão não deve ser usada sem verificar o tamanho. A recomendação operacional que os resultados sustentam é preferir o `nostitch` quando houver lacunas interiores, com a ressalva de que o seu custo de poder só foi medido em células em que ele não descarta trechos, e, em qualquer caso, relatar três números: a fração de lacunas vizinhas de troca de líder, a autocorrelação do resíduo e o tamanho do teste numa simulação sob o nulo com a estrutura real de mandatos. Uma lacuna sistemática, como a de uma prova suspensa na pandemia, pode ser mais problemática quando se alinha da mesma forma às trocas em muitas unidades, caso que as células deste artigo não isolam.

O `nostitch` não é uma garantia universal. Ele tirou a inflação de dezenas de pontos nas células testadas (a de 6,2% não exclui alguns pontos), mas a tradução mostra que o pacote continua agrupando a mesma pessoa entre trechos, o que deixa uma covariância residual de ordem ρ^2 entre os dois lados de uma lacuna quando o mesmo líder governa os dois. O mesmo vale para o trecho de uma linha que o pacote mantém (o período 10, com a lacuna no 9): nunca é sorteado, mas, quando a mesma pessoa aparece nos dois trechos, continua no grupo dela no outro trecho. As células com `nostitch` ficam alguns pontos acima da linha de base sem lacuna do pacote (Seção 5.2); essas ligações são uma explicação compatível, não isolada, e nada garante o mesmo comportamento em painéis com outra estrutura.

6.2 O que não muda

Nenhum resultado publicado de Berry e Fowler foi reanalisado aqui. As simulações de tamanho do artigo original continuam válidas para os desenhos sem lacuna que elas cobrem.

Uma rejeição publicada só pode ter sido inflada por este mecanismo se a amostra usada tinha lacunas interiores e correlação serial, e o sentido do efeito depende de onde as lacunas caíam em relação às fronteiras dos mandatos. No código de replicação (Berry & Fowler, 2020), todas as chamadas do `rifle` que geram as Tabelas 2 a 4 usam a costura padrão, e as de governadores, prefeitos e CEOs usam também a opção `growth`, que calcula a variação só entre períodos seguidos: um nível faltante isolado no meio da série vira uma lacuna de dois períodos na série de variações (um bloco de L níveis faltantes vira $L + 1$ períodos ausentes), e a autocorrelação muda ao passar de níveis para variações (a tradução deste artigo não implementa essa opção). Se aqueles painéis têm lacunas interiores vizinhas de trocas, e de que tamanho são, não foi verificado aqui; responder isso exige reanalisar cada aplicação.

6.3 Limites

Os limites principais são o código traduzido, o gerador autorregressivo e uma fonte não lida.

- A tradução do código foi testada à mão, mas não confrontada com o Stata.
- O ruído sintético é autorregressivo de ordem um; outras estruturas de dependência não foram testadas nas células de capa, embora o estudo pré-registrado tenha conferido o tamanho do teste por trechos sob seis geradores alternativos: cinco ficaram entre 4,6% e 6,2%, e o não estacionário ficou conservador, em 1,2%.
- A varredura da literatura (OpenAlex, Semantic Scholar, Crossref, a primeira página do Google Scholar, a ajuda e o código do pacote, o material suplementar e o código de replicação de Berry e Fowler) não achou a distorção documentada, com confiança média: o Google Scholar bloqueou as páginas seguintes, e o texto completo de Smith e Gray

(2021), a única extensão metodológica do RIFLE localizada, não foi obtido: o RePEc não registra restrição de download, mas a página da editora negou acesso em 1 de novembro de 2026, e uma nova busca em 3 de novembro, em 30 vias (editora, agregadores de acesso aberto, repositórios e páginas dos autores), não achou versão aberta. Se aquela revalidação em séries históricas tiver tratado de lacunas, a parte deste artigo que diz que o problema não estava documentado cai; a quantificação neste painel permanece, e a originalidade do diagnóstico dependerá da comparação com aquele trabalho.

- A primeira varredura não leu a ajuda do pacote e deixou passar o `nostitch`. O erro foi registrado e corrigido antes da redação.

7. Conclusão

Um período faltando no lugar errado, repetido em muitos municípios, basta para o teste de liderança encontrar um prefeito que não existe. A costura de lacunas que o artigo original de Berry e Fowler (2021) descreve, e que o pacote oficial aplica por padrão, não produz este viés quando a lacuna fica na borda da série ou quando o resultado não tem correlação serial (com $\rho = 0$, a célula testada deu tamanho compatível com 5%). Quando a lacuna cai junto de uma troca, separando prefeitos diferentes, e o resultado tem uma correlação modesta como a calibrada a partir do índice do estudo, o teste rejeita demais em painéis grandes: na célula vizinha de troca, 6,8% com 50 municípios (intervalo que ainda inclui 5%), 14,2% com 200 e 89,4% com 5.468. Lacunas dentro de um mandato podem empurrar a estatística para qualquer lado, e o retorno do prefeito depois da lacuna, nos casos calculados, para o lado conservador. O critério explícito da ajuda do pacote, uma lacuna longa ou outra razão não especificada, não nomeia a posição da lacuna em relação às trocas, e é ela que precisa entrar no diagnóstico. A correção já existe e é dos

autores: a opção `nostitch`, que tirou a inflação de dezenas de pontos nas células testadas, com poder semelhante ao do controle onde foi medido (Seção 5.1). No painel inteiro, ela deixa o teste conservador, entre 1,2% e 2,0%, acima dos 0,2% do pacote sem lacuna.

Quatro direções ficam abertas: (i) confrontar a tradução com o próprio Stata, com o arquivo `.do` que acompanha o pacote de replicação (Flores, 2026); (ii) medir, nos dados de replicação que Berry e Fowler publicaram e em outras aplicações, quantas lacunas interiores caem vizinhas de trocas de líder; (iii) isolar a causa do conservadorismo do pacote sem lacuna, que é maior no painel inteiro sem que número de unidades e composição tenham sido separados, e testar outras estruturas de dependência e o efeito dos líderes que voltam ao cargo; (iv) avaliar uma variante do `nostitch` que trate cada passagem do líder como grupo próprio, retirando da soma explicada os termos que ligam a mesma pessoa através da lacuna (Seção 6.1).

Disponibilidade de dados e código

O código das simulações, a tradução do `rifle.ado` com os testes, as saídas com hash e a cadeia de proveniência estão no pacote de replicação deste artigo (Flores, 2026), no repositório público https://github.com/ulissesflores/rifle-gap-bias e arquivado no Zenodo com o DOI https://doi.org/10.5281/zenodo.24044367, com o código sob a licença Apache-2.0 e o texto e as figuras sob a CC BY 4.0. O pacote de replicação também traz um arquivo `.do` para reproduzir as células centrais no Stata e um painel anonimizado de mandatos (cada par de prefeito e município com um identificador único no painel inteiro, sem CPF, porque o pacote agrupa os líderes pelo identificador em todas as unidades ao mesmo tempo, e períodos numerados de 1 a 10, porque o `nostitch` reconhece a contiguidade por período mais um). Os dados de origem são públicos: TSE (2024), Inep (2024), Tesouro Nacional (2025) e Ministério da Saúde (2025).

Referências

Akhtari, M., Moreira, D., & Trucco, L. (2022). Political turnover, bureaucratic turnover, and the quality of public services. *American Economic Review, 112*(2), 442-493. https://doi.org/10.1257/aer.20171867

Berry, C. R., & Fowler, A. (2018). *RIFLE: Stata module to perform randomization inference for leader effects* (Statistical Software Components S458461). Boston College Department of Economics. https://ideas.repec.org/c/boc/bocode/s458461.html

Berry, C. R., & Fowler, A. (2020). *Replication data for: Leadership or luck? Randomization inference for leader effects in politics, business, and sports* [Conjunto de dados e código, Stata 16.1; arquivos datados de novembro de 2020]. https://voices.uchicago.edu/fowler/research

Berry, C. R., & Fowler, A. (2021). Leadership or luck? Randomization inference for leader effects in politics, business, and sports. *Science Advances, 7*(4), eabe3404. https://doi.org/10.1126/sciadv.abe3404

Brollo, F., & Nannicini, T. (2012). Tying your enemy's hands in close races: The politics of federal transfers in Brazil. *American Political Science Review, 106*(4), 742-761. https://doi.org/10.1017/S0003055412000433

Canay, I. A., Romano, J. P., & Shaikh, A. M. (2017). Randomization tests under an approximate symmetry assumption. *Econometrica, 85*(3), 1013-1030. https://doi.org/10.3982/ECTA13081

Clopper, C. J., & Pearson, E. S. (1934). The use of confidence or fiducial limits illustrated in the case of the binomial. *Biometrika, 26*(4), 404-413. https://doi.org/10.1093/biomet/26.4.404

Fitza, M. A. (2014). The use of variance decomposition in the investigation of CEO effects: How large must the CEO effect be to rule out chance? *Strategic Management Journal, 35*(12), 1839-1852. https://doi.org/10.1002/smj.2192

Flores, C. U. (2026). *Does a mayor improve a city beyond chance? Missing data at a change of mayor makes the test say yes: Replication package* (Versão 1.0.0) [Software e dados]. Codex Hash Research Laboratory. Zenodo. https://doi.org/10.5281/zenodo.24044367. Repositório de código: https://github.com/ulissesflores/rifle-gap-bias

Inep. (2024). *Microdados e resultados do Saeb* [Conjunto de dados]. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. https://download.inep.gov.br

Jones, B. F., & Olken, B. A. (2005). Do leaders matter? National leadership and growth since World War II. *Quarterly Journal of Economics, 120*(3), 835-864. https://doi.org/10.1162/003355305774268165

Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics, 17*(3), 1217-1241. https://doi.org/10.1214/aos/1176347265

Lahiri, S. N. (2003). *Resampling methods for dependent data*. Springer. https://doi.org/10.1007/978-1-4757-3803-2

Lehmann, E. L., & Romano, J. P. (2005). *Testing statistical hypotheses* (3rd ed.). Springer. https://doi.org/10.1007/0-387-27605-X

Ministério da Saúde. (2025). *Sistema de Informações sobre Nascidos Vivos (Sinasc) e Sistema de Informações sobre Mortalidade (SIM)* [Conjunto de dados]. DataSUS. https://opendatasus.saude.gov.br

Nickell, S. (1981). Biases in dynamic models with fixed effects. *Econometrica, 49*(6), 1417-1426. https://doi.org/10.2307/1911408

Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences, 115*(11), 2600-2606. https://doi.org/10.1073/pnas.1708274114

Politis, D. N., & Romano, J. P. (1994). The stationary bootstrap. *Journal of the American Statistical Association, 89*(428), 1303-1313. https://doi.org/10.1080/01621459.1994.10476870

Quigley, T. J., & Graffin, S. D. (2017). Reaffirming the CEO effect is significant and much larger than chance: A comment on Fitza (2014). *Strategic Management Journal, 38*(3), 793-801. https://doi.org/10.1002/smj.2503

Smith, D. S., & Gray, T. R. (2021). Looking for leadership in historical context: An extension of the RIFLE method of randomization inference. *Journal of Historical Political Economy, 1*(2), 215-234. https://doi.org/10.1561/115.00000010

Tesouro Nacional. (2025). *Siconfi: Declaração de Contas Anuais (DCA), Anexo I-C, exercícios 2013 a 2024* [Conjunto de dados]. https://apidatalake.tesouro.gov.br/ords/siconfi/tt/dca

TSE. (2024). *Repositório de dados eleitorais: candidatos e resultados, 2004 a 2020* [Conjunto de dados]. Tribunal Superior Eleitoral. https://dadosabertos.tse.jus.br

Winkler, A. M., Ridgway, G. R., Webster, M. A., Smith, S. M., & Nichols, T. E. (2014). Permutation inference for the general linear model. *NeuroImage, 92*, 381-397. https://doi.org/10.1016/j.neuroimage.2014.01.060